

# Rastreamento e Análise da Trajetória de Veículos em Vídeos de Monitoramento de Tráfego Utilizando Filtro de Partículas Adaptativo.

Alessandro Bof de Oliveira<sup>1</sup>, Jacob Scharcanski<sup>1</sup>

<sup>1</sup>Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)  
Caixa Postal 15.064 – 91.501-970 – Porto Alegre – RS – Brazil

{aboliveira,jacobs}@inf.ufrgs.br

**Abstract.** *This paper presents algorithms to detect and track vehicles in video surveillance. We have done the vehicular tracking with and without total occlusions. Using cubic spline interpolation of the tracking data, we present a tracking vehicles trajectory analysis.*

**Resumo.** *Este trabalho apresenta o desenvolvimento de algoritmos para detecção e rastreamento de veículos em vídeos de monitoramento de tráfego. Nós realizamos o rastreamento dos veículos em situações livres e na presença de oclusões totais. Utilizando os dados obtidos pelo rastreamento, apresentamos uma análise da trajetória dos veículos rastreados usando interpolação spline cúbica para posterior análise de comportamento dos mesmos.*

## 1. Introdução

O rastreamento de veículos constitui um problema de grande importância na área de processamento de imagens, pois encontra inúmeras aplicações como vigilância, monitoramento de tráfego (contagem e classificação de veículos) e detecção automática eventos (como acidentes ou direção perigosa). A abordagem de rastreamento de veículos utilizando filtro de partículas tem mostrado bons resultados. Nessa abordagem uma região de interesse a ser rastreada, tem associada a si uma distribuição de cores [Nummiaro et al 2002], que posteriormente será comparada através de medidas de similaridade com a distribuição de cores de outras regiões (partículas) para a predição da posição estimada da região de interesse através de métodos de Monte Carlo.

Para a realização efetiva do rastreamento de veículos em vídeos de monitoramento de tráfego, é importante garantir que o rastreamento não apresente falhas, como as causadas por oclusões parciais e totais. As oclusões são bastante comuns nesse tipo de vídeo, uma vez que temos observamos veículos sofrendo oclusões de outros veículos, além de oclusões sofridas por pontes, viadutos e sinais de trânsito. Além disso, torna-se importante limitar regiões da imagem onde os veículos serão rastreados, definindo uma condição de contorno para o início e o término do processo de rastreamento. Os dados obtidos no rastreamento de objetos são utilizados no desenvolvimento de trajetórias dos veículos rastreados.

## 2. Detecção de Movimento em Vídeos

Na detecção de movimento nas seqüências de vídeos, nós classificamos os pixels da imagem como sendo pixels de fundo (background) ou pixels de destaque (foreground) de acordo com a variabilidade temporal dos valores de sua intensidade. Os pixels classificados como destaque apresentam grande variabilidade de intensidade e são ditos que representam objetos que estão se movendo no vídeo. Entretanto, em vídeos de monitoramento de tráfego, é bastante comum que o fundo também apresente algum tipo de movimento. Isso se deve por exemplo, a presença de vegetação que oscila devido ao vento. Portanto para conseguir distinguir o movimento de uma vegetação (fundo) do movimento de um veículo (destaque), temos que usar métodos que sejam capazes de diferenciar tais comportamento de movimento.

Nesse trabalho nós utilizamos a classificação dos pixels em fundo ou destaque, utilizando um classificador probabilístico, o qual utiliza uma função de probabilidade não paramétrica [Bishop 2006].

## 3. Rastreamento Utilizando Filtro de Partículas

O filtro de partículas foi desenvolvido para rastrear ou estimar de forma recursiva uma coleção de variáveis ocultas (estados), sujeitas a um processo Markoviano, baseado unicamente nas observações indiretas dessas variáveis, sendo esse processo tipicamente não-linear e possuindo ruído não-gaussiano [Silva 2006]. A abordagem do filtro de partículas consiste na construção da representação da função densidade de probabilidade *a posteriori*, que pode apresentar comportamento multi-modal, baseada numa amostra  $w$  representada por um conjunto de estados  $s$  e suas respectivas funções de importância  $\pi$  os quais são denominados partículas.

Dessa forma, podemos escrever um conjunto de partículas na forma:

$$w_t = \{(s_t^{(1)}, \pi_t^{(1)}), (s_t^{(2)}, \pi_t^{(2)}), \dots, (s_t^{(N)}, \pi_t^{(N)})\} \quad \text{eq.1}$$

Para que possamos escrever a função densidade de probabilidade condicional a posteriori vamos definir como sendo  $s_t$  a variável oculta ou estado e  $\xi_t$  as observações ambas realizadas no tempo discreto  $t \in N$ . Vamos definir ainda a notação de  $S_t$  e  $\Xi_t$  para respectivamente o conjunto de estados ocultos e observações do tempo inicial até o tempo  $t$ , ou seja:

$$S_t \equiv \{s_1, s_2, \dots, s_t\} \text{ e } \Xi_t \equiv \{\xi_1, \xi_2, \dots, \xi_t\} \quad \text{eq.2}$$

Estamos mais interessados na probabilidade condicional a posteriori para um determinado tempo  $t$ , portanto podemos obter  $p(s_t | \Xi_t)$  através da marginalização (ou filtragem) de  $p(S_t | \Xi_t)$ .

$$p(s_t | \Xi_t) = \int \dots \int_{R^{n_s} \quad R^{n_s}} p(s_0, \dots, s_t | \Xi_t) ds_0 \dots ds_{t-1} \quad \text{eq.3}$$

Ou na forma mais compacta, segundo nossa notação:

$$p(s_t | \Xi_t) = \int_{(R^{n_s})^{t-1}} p(S_t | \Xi_t) dS_{t-1} \quad \text{eq.4}$$

Lembrando do teorema de Bayes que define a probabilidade condicional a posteriori em termos da probabilidade condicional a priori, ou seja:

$$p(A|B) = \frac{p(A,B)}{p(B)}, \quad \text{e} \quad p(B|A) = \frac{p(B,A)p(A)}{p(B)} \quad \text{eq.5}$$

Vamos escrever  $p(s_t | \Xi_t)$  como:

$$p(s_t | \Xi_t) = \frac{p(\Xi_t | s_t)p(s_t)}{p(\Xi_t)} = \frac{p(\xi_t, \Xi_{t-1} | s_t)p(s_t)}{p(\xi_t, \Xi_{t-1})} \quad \text{eq.6}$$

$$= \frac{p(\xi_t | \Xi_{t-1}, s_t)p(\Xi_{t-1} | s_t)p(s_t)}{p(\xi_t | \Xi_{t-1})p(\Xi_{t-1})} \quad \text{eq.7}$$

$$\text{Onde: } p(\Xi_{t-1} | s_t)p(s_t) = p(s_t | \Xi_{t-1})p(\Xi_{t-1}) \quad \text{eq.8}$$

Substituindo na equação, ficamos com:

$$p(s_t | \Xi_t) = \frac{p(\xi_t | s_t)p(s_t | \Xi_{t-1})p(\Xi_{t-1})}{p(\xi_t | \Xi_{t-1})p(\Xi_{t-1})} \quad \text{eq.9}$$

E finalmente:

$$p(s_t | \Xi_t) = \frac{p(\xi_t | s_t)p(s_t | \Xi_{t-1})}{p(\xi_t | \Xi_{t-1})} \quad \text{eq.10}$$

Porém ainda não precisamos definir quem são  $p(s_t | \Xi_{t-1})$  e  $p(\xi_t | \Xi_{t-1})$ . Para o primeiro termo, vamos escrever:

$$p(s_{t+1}, s_t | \Xi_t) = p(s_{t+1} | s_t, \Xi_t)p(s_t | \Xi_t) \quad \text{eq.11}$$

Como estamos considerando nosso processo Markoviano, a probabilidade de nosso sistema estar num determinado estado  $s_{t+1}$ , irá depender somente de ele ter ocupado o estado  $s_t$ . Dessa forma, podemos escrever  $p(s_{t+1} | s_t, \Xi_t)$  como  $p(s_{t+1} | s_t)$ :

$$p(s_{t+1}, s_t | \Xi_t) = p(s_{t+1} | s_t)p(s_t | \Xi_t) \quad \text{eq.12}$$

Integrando ambos os lados da equação em relação à  $s_t$ , ficamos com:

$$\int_{R^{n_s}} p(s_{t+1}, s_t | \Xi_t) ds_t = \int_{R^{n_s}} p(s_{t+1} | s_t)p(s_t | \Xi_t) ds_t \quad \text{eq.13}$$

$$p(s_{t+1} | \Xi_t) = \int_{R^{n_s}} p(s_{t+1} | s_t) p(s_t | \Xi_t) ds_t \quad \text{eq.14}$$

Essa equação é chamada de passo de predição, atualização no tempo, ou ainda é conhecida como equação de Chapman-Kolmogorov.

Para  $p(\xi_t | \Xi_{t-1})$ , vamos desenvolver um raciocínio semelhante. Vamos escrever:

$$p(\xi_t, s_t | \Xi_{t-1}) = p(\xi_t | s_t, \Xi_{t-1}) p(s_t | \Xi_{t-1}) = p(\xi_t | s_t) p(s_t | \Xi_{t-1}) \quad \text{eq.15}$$

Podemos escrever  $p(\xi_t | s_t, \Xi_{t-1}) = p(\xi_t | s_t)$  pois estamos considerando que nossa observação  $\xi_t$  depende do estado atual  $s_t$ .

Vamos integrar essa equação em relação à  $s_t$  (marginalização):

$$p(\xi_t | \Xi_{t-1}) = \int_{R^{n_s}} p(\xi_t | s_t) p(s_t | \Xi_{t-1}) ds_t \quad \text{eq.16}$$

Chegando a equação de atualização das observações.

Ficamos com as equações:

$$p(s_t | \Xi_t) = \frac{p(\xi_t | s_t) p(s_t | \Xi_{t-1})}{p(\xi_t | \Xi_{t-1})} \quad \text{eq.17}$$

Onde:

$$p(s_{t+1} | \Xi_t) = \int_{R^{n_s}} p(s_{t+1} | s_t) p(s_t | \Xi_t) ds_t \quad \text{eq.18}$$

$$p(\xi_t | \Xi_{t-1}) = \int_{R^{n_s}} p(\xi_t | s_t) p(s_t | \Xi_{t-1}) ds_t \quad \text{eq.19}$$

O problema consiste em calcular as integrais acima. Caso consideremos um sistema linear, com probabilidades gaussianas, podemos resolver as equações de forma analítica, obtendo assim a solução para o filtro de Kalman. Porém para casos mais gerais, onde o sistema é não linear, e as probabilidades não-gaussianas, como é o caso abordado nesse trabalho, é necessário utilizar outra abordagem para resolver as integrais, pois além de não possuírem solução analítica, sua resolução numérica por métodos diretos se mostra computacionalmente inviável. Para tal, vamos utilizar o método de Monte Carlo sequencial, que será discutido na próxima seção.

### 3.1. Método de Monte Carlo

Para encontrar o valor da posição do objeto rastreado, é necessário calcular o valor esperado do estado  $s_t$ :

$$E_{f(s)}[g(s)] = \int g(s) f(s) ds \quad \text{eq.20}$$

$$E_{p(s_t | \Xi_t)}[g(s_t)] = \int g(s_t) p(s_t | \Xi_t) ds_t \quad \text{eq.21}$$

Onde podemos definir a função  $g(s_t) = s_t$ , obtendo:

$$E_{p(s_t|\Xi_t)}[s_t] = \int s_t p(s_t | \Xi_t) ds_t \quad \text{eq.22}$$

Entretanto, como não conhecemos a função densidade de probabilidade *a posteriori*  $p(s_t | \Xi_t)$ , não poderemos resolver a eq. 22 diretamente. Vamos contornar esse problema, utilizando o método de Monte Carlo, para estimar o valor esperado do estado  $s_t$ .

O método de Monte Carlo [Schön 2003] consiste na utilização de uma amostra de  $N$  estados  $s_t^{(i)}$ , com  $i=1, \dots, N$ , gerados através de uma função densidade de probabilidade conhecida, com o objetivo de representar a função densidade de probabilidade *a posteriori* da posição do objeto rastreado. Utilizando essa aproximação discreta, podemos calcular o valor aproximado da posição do objeto rastreado através do conjunto de estados amostrado e de seus valores de verossimilhança.

Vamos definir um conjunto de estados e suas respectivas probabilidades de verossimilhança associadas (pesos) como um conjunto de partículas:

$$w_t = \{(s_t^{(1)}, \pi_t^{(1)}), (s_t^{(2)}, \pi_t^{(2)}), \dots, (s_t^{(N)}, \pi_t^{(N)})\} \quad \text{eq.23}$$

O peso, ou probabilidade de ocorrência de um estado pode ser aproximado na forma:

$$\pi_t^{(i)} \propto p(\xi_t | s_t^{(i)}) \quad \text{eq.24}$$

Sendo os pesos normalizados:

$$\tilde{\pi}_t^{(i)} = \frac{\pi_t^{(i)}}{\sum_{j=1}^N \pi_t^{(j)}} \quad i = 1, 2, \dots, N \quad \text{eq.25}$$

Vamos ainda aproximar a probabilidade condicional à posteriori como sendo:

$$\hat{p}_N(s_t | \Xi_t) = \sum_{i=1}^N \tilde{\pi}_t^{(i)} \delta(s_t - s_t^{(i)}) \quad \text{eq.26}$$

Onde  $\delta$  representa a função delta de Dirac. Aplicando essa aproximação a equação do valor estimado [Karlsson 2002]:

$$\hat{s}_{t|t} = \int s_t \hat{p}_N(s_t | \Xi_t) ds_t = \int s_t \sum_{i=1}^N \tilde{\pi}_t^{(i)} \delta(s_t - s_t^{(i)}) ds_t = \sum_{i=1}^N \tilde{\pi}_t^{(i)} s_t^{(i)} \quad \text{eq.27}$$

Obtendo assim o valor estimado do estado no tempo  $t$ , dado as observações também no tempo  $t$ .

### 3.3. Filtro de Partículas Adaptativo

Os pesos, ou importâncias associados aos estados das partículas, utilizados no método de Monte Carlo para calcular o valor estimado da função densidade de probabilidade condicional a posteriori, podem ser encontrados através do grau de similaridade entre o histograma de cores associado ao estado da  $n$ -ésima partícula e o histograma de cores da região do alvo a ser rastreado.

O grau de similaridade é obtido através da distância de Bhattacharyya de dois histograma de cores a serem comparadas [Pérez et al 2002]. Considerando dois histogramas  $p$  e  $q$ , o coeficiente de Bhattacharyya [Aherne et al 1997] é definido como:

$$\rho[p, q] = \sum_{u=1}^m \sqrt{p^{(u)} q^{(u)}} \quad \text{eq.28}$$

Quando dois histogramas são idênticos, o coeficiente de Bhattacharyya  $\rho = 1$ . Portanto os valores do coeficiente variam entre 0 e 1. Podemos ainda definir a distância entre duas distribuições utilizando a fórmula:

$$d = \sqrt{1 - \rho[p, q]} \quad \text{eq.29}$$

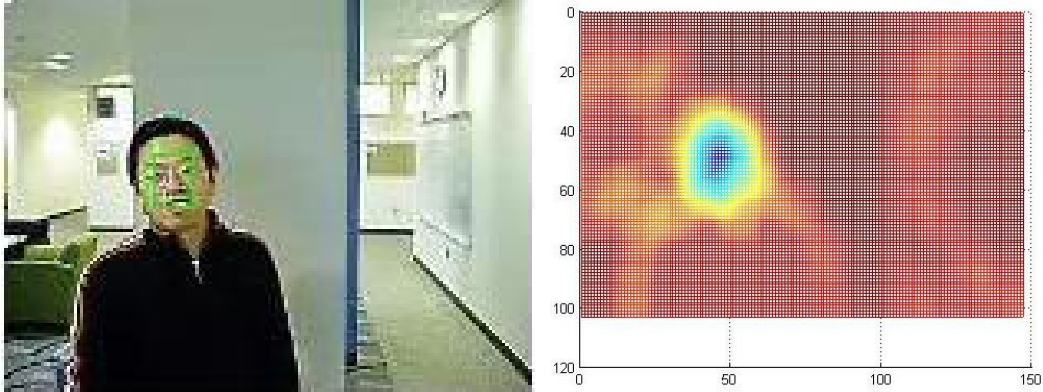
Conhecida como distância de Bhattacharyya.

Dessa forma, vamos definir os pesos  $\pi^{(n)}$  (onde  $n$  refere-se a  $n$ -ésima partícula):

$$\pi^{(n)} = \frac{1}{\sqrt{2\pi}\sigma} e^{\frac{-(1-\rho[p_{x^{(n)}}, q])}{2\sigma^2}} \quad \text{eq.30}$$

Ou seja, quanto maior a similaridade entre o histograma da região do alvo e da partícula em questão maior será o peso da partícula, e maior será sua contribuição na integração de Monte Carlo.

A figura abaixo exemplifica as diferenças de similaridade entre as regiões da imagem [MATLAB] e a região alvo:



**Figura 1. Imagem mostrando a região alvo a ser rastreada, e gráfico da distância de Bhattacharyya entre a região do alvo e a imagem. A cor azul representa menor distância entre as distribuições.**

### 3.4. Função de Transição de Estados Sem a Presença de Oclusão

Os estados das partículas, definidos como  $s_t^{(i)}$  (onde  $i = 1, \dots, N$ ), são definidos como as coordenadas  $(x, y)$  da posição em pixels na imagem, ou seja  $s_t^{(i)} = [x, y]^t$ . A amostragem desses estados será realizada através de uma função de probabilidade de transição de estados. Em situações de rastreamento onde não houver oclusões, vamos definir a

função de probabilidade de transição de estados como sendo uma função de densidade de probabilidades normal bivariada com correlação zero ( $\rho = 0$ ):

$$p_N(\vec{s}_t^{(i)} | \vec{s}_{t-1}^{(i)}) = \frac{1}{2\pi\sigma_w^2} \exp\left(-\frac{1}{2} \left[ \frac{x'^2 + y'^2}{\sigma_w^2} \right]\right) \text{ eq.31}$$

Onde  $\sigma_w$  é variância da distribuição normal bivariada. Essa distribuição é utilizada porque não assumimos *a priori* nenhuma informação sobre o tipo de movimento descrito pelo objeto rastreado. Por isso, qualquer direção é equiprovável para realizar a amostragem de estados.

### 3.5. Função de Transição de Estados Durante a Oclusão

Durante a oclusão total, a utilização da função de transição de estados Normal (seção 3.4) não produz bons resultados. Isso porque durante a oclusão a informação sobre o objeto esta perdida. Portanto, a função de verossimilhança dos estados que constituem as partículas, retornam valores pequenos e muito próximos entre si. Com isso a estimativa da posição do objeto rastreado através do método de Monte Carlo, produz resultados errôneos, uma vez que a função densidade de probabilidade *a posteriori* não esta sendo amostrada de forma satisfatória.

Para contornar esse problema, nós utilizamos uma outra função de transição para os estados. Essa função é definida pela junção de uma função densidade de probabilidade Normal e uma função de densidade de probabilidade Rayleigh:


$$R(x | \sigma_R) = \frac{x}{\sigma_R^2} \exp\left(-\frac{x^2}{2\sigma_R^2}\right) \text{ eq.32}$$

$$N(y | \mu_y, \sigma_N) = \frac{1}{\sqrt{2\pi}\sigma_N} \exp\left(-\frac{(y - \mu_y)^2}{2\sigma_N^2}\right) \text{ eq.33}$$

Considerando uma função densidade de probabilidade conjunta bidimensional, sem correlação, podemos escrever a função densidade de probabilidade Normal-Rayleigh para transição de estados como:

$$p_{NR}(\vec{s}_t^{(i)} | \vec{s}_{t-1}^{(i)}) = R(x | \sigma_R)N(y | \mu_y, \sigma_N), \text{ eq. 34}$$

$$p_{NR}(\vec{s}_t^{(i)} | \vec{s}_{t-1}^{(i)}) = \frac{x'}{\sqrt{2\pi}\sigma_w^3} \exp\left(-\frac{(x'^2 + y'^2)}{2\sigma_w^2}\right) \text{ eq.35}$$



**Figura 2. Gráfico da função densidade de probabilidade Normal-Rayleigh.**


Dessa forma nós introduzimos um termo assimétrico na função de transição de estados, que irá empurrar as partículas, isto é, a amostragem dos estados na direção de movimento do objeto rastreado sob a oclusão total. Assim o objeto rastreado por ser corretamente amostrado quando sair da situação de oclusão total. A direção de movimento é determinada pela média da velocidade do objeto nas direções  $x$  e  $y$  antes da oclusão. Durante a oclusão total, a direção de maior velocidade será amostrada com a função densidade de probabilidade Rayleigh enquanto a direção ortogonal será amostrada com a função densidade de probabilidade Normal.

#### **4. Exemplos de Detecção e Rastreamento de Veículos**

As simulações realizadas nesse trabalho utilizaram a detecção de movimento baseada em classificação probabilística de background e foreground utilizando modelo não-paramétrico (seção 2), e rastreamento dos objetos detectados utilizando o filtro de partícula adaptativo (seção 3). A inicialização e término do rastreamento são definidos *a priori* pelo usuário através da marcação de linhas de início e fim do rastreamento. Os vídeos utilizados nesse trabalho foram obtidos através das câmeras de vigilância e monitoramento de tráfego da empresa privada de administração de rodovias Concepa [CONCEPA].

Na figura 6 mostramos um exemplo de detecção e rastreamento de veículo utilizando vídeo de monitoramento de tráfego da Concepa. Na figura 6(a) temos o veículo (carro branco) antes de cruzar a linha de indicação de início de rastreamento definida pelo usuário. Na figura 6(b) temos o momento em que o veículo cruza linha de indicação do início do rastreamento e começa a ser rastreado. Na figura 6(c) o veículo esta sendo rastreado dentro dos limites de detecção e finalmente na figura 6(d) o veículo já deixou a linha que marca o término do rastreamento.






**Figura 3. Exemplo de detecção e rastreamento de um veículo no vídeo de monitoramento de tráfego da Concepa. Figura (a) frame 02, figura (b) frame 09, figura (c) frame 20 e figura (d) frame 31 da sequência de vídeo.**

## **5. Análise de Trajetória de Movimento dos Objetos Rastreados**

Para realizar a análise de trajetória do movimento dos objetos rastreados, nós utilizamos os resultados sobre a posição do objeto para cada instante de tempo  $t$  obtido na etapa de rastreamento. Posteriormente utilizamos uma interpolação dos pontos referentes à posição do objeto utilizando o método spline cúbica [Bishop 2006], a fim de obter uma curva suave e que representa a trajetória espacial do objeto.



**Figura 4. Exemplo de análise de trajetória de movimento. Imagem com efeito estroboscópico para facilitar a visualização do movimento do objeto rastreado. A faixa azul indica a trajetória do objeto estimada pela interpolação dos pontos utilizando a função spline cúbica.**



**Figura 5. Exemplo de trajetória de movimento. Imagem com efeito estroboscópico para facilitar a visualização do movimento do objeto rastreado. A faixa verde indica a trajetória do objeto estimada pela interpolação dos pontos utilizando a função spline cúbica.**

## 5. Perspectivas e Trabalhos futuros

As perspectivas de trabalhos futuros seguem três linhas complementares.

- Desenvolvimento de métodos mais robustos de rastreamentos de veículos baseados em filtro de partículas. Nós estamos desenvolvendo filtro de partículas multi-características, que utilizam mais de uma característica de observação do objeto rastreado (por exemplo, histograma de cores e textura).

- Desenvolvimento de métodos para análise do comportamento dos objetos rastreados: Utilização das trajetórias dos objetos para a construção de uma função espacial de probabilidades para análise de comportamento do movimento (detecção de movimentos atípicos ou não usuais).
- Utilização de grafos para detectar comportamento de grupo: utilização de grafos para analisar o relacionamento de um grupo de objetos em movimento, e identificar comportamentos atípicos.

## 6. Agradecimentos

Agradecemos a CONCEPA por disponibilizar as seqüências de vídeo utilizadas nesse trabalho. Também gostaria de agradecer ao CNPq pelo financiamento desse projeto.

## Referências

- Aherne, F. J., Thacker, N. A. and Rockett, P. I. (1997) “The Bhattacharyya Metric as an Absolute Similarity Measure for Frequency Coded Data”, *Kybernetika*, vol. 32, no. 4, pp. 001-007.
- Bishop, C. (2006) “Pattern Recognition and Machine Learning”, Singapore, CONCEPA [http:// www.concepa.com.br](http://www.concepa.com.br).
- <http://groups.inf.ed.ac.uk/vision/CAVIAR/CAVIARDATA1>
- Karlsson, R. (2002) “Simulation Based Methods for Target Tracking”, Thesis, Linköping Universitet, Sweden.
- KOGS/IAKS, Universität Karlsruhe, accessed in April, 2007.
- [http://i21www.ira.uka.de/image\\_sequences/](http://i21www.ira.uka.de/image_sequences/)
- MATLAB, Matlab is trademark of The MathWorks.
- Nummiaro, K., Koller-Meier, E. and Gool, L. V. (2002) “Object Tracking with an Adaptive Color-Based Particle Filter”, DAGM 2002, LNCS 2449, pp. 353-360.
- Pérez, P., Hue, C., Vermaak, J. and Gangnet, M. (2002) “Color-Based Probabilistic Tracking”, ECCV, LNCS 2350, pp. 661-675.
- Sato, Y., Okatani, T. and Deguchi, K. (2004) “A Color-Based Probabilistic Tracking by Using Graphical Models”, Proc. Of 2004 IEEE/RSJ Int. Conf. on Intelligent Robots and Systems, Sendai, Japan.
- Schön, T. (2003) “On Computational Methods for Nonlinear Estimation”, Thesis, Linköping Universitet, Sweden.
- Silva, P. R. A. (2006) “Filtro de Partículas Aperfeiçoado para Estimação de Postura de Robôs Móveis”, Tese, ITA, Brasil.