

UNIVERSIDADE FEDERAL DO PAMPA

Rodrigo Siveris Klein

**Localização e Rastreamento de Veículos
através da Identificação de Padrões de
Imagens utilizando Redes Neurais**

Alegrete
2023

Rodrigo Siveris Klein

**Localização e Rastreamento de Veículos através da
Identificação de Padrões de Imagens utilizando
Redes Neurais**

Projeto de Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Ciência da Computação da Universidade Federal do Pampa como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Orientador: Prof. <Doutor> Alessandro Bof de Oliveira

Alegrete
2023

Rodrigo Siveris Klein

**Localização e Rastreamento de Veículos através da
Identificação de Padrões de Imagens utilizando
Redes Neurais**

Projeto de Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Ciência da Computação da Universidade Federal do Pampa como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Projeto de Trabalho de Conclusão de Curso defendido e aprovado em de
de
Banca examinadora:

**Prof. <Doutor> Alessandro Bof de Oliveira
<UNIPAMPA>**

**Prof. <Doutor> Mauricio Braga de Paula
<UFPEL>**

**Prof. <Doutor> Eliezer Soares Flores
<UNIPAMPA>**

RESUMO

O presente trabalho propõe um sistema de rastreamento e localização de veículos com base em imagens de trânsito, utilizando técnicas de processamento de imagens e redes neurais. O projeto se fundamenta na análise e comparação de histogramas de cores para a classificação e identificação de padrões em uma sequência de imagens de rastreamentos realizados pelo software YOLOv8 (You Only Look Once, versão 8). No processo de comparação dos histogramas será utilizado o método da Distância de Hellinger utilizando o coeficiente de Bhattacharyya para verificarmos se a distância condiz com a possibilidade de um veículo ser o mesmo ao longo de um trajeto específico. O objetivo principal do trabalho proposto pretende oferecer uma solução alternativa ~~das~~^{às} atuais já existentes no mercado, como o método de rastreamento ByteTrack presente no software YOLOv8, podendo resultar em uma solução possível de comparação com as outras apresentadas. O rastreamento dos veículos no trânsito oferece uma gama de benefícios que vão desde o aumento da segurança, possibilitando uma rápida localização em caso de roubo, até a capacidade de monitorar rotas e tempos de entrega, melhorando a eficiência de operações logísticas.

Palavras-chave: Rastreamento de Veículos. Redes Neurais. Análise de Histogramas. YOLOv8. Distância de Hellinger. Coeficiente de Bhattacharyya.

ABSTRACT

The present work proposes a vehicle tracking and localization system based on traffic images, using image processing techniques and neural networks. The project is based on the analysis and comparison of color histograms for the classification and identification of patterns in a sequence of tracking images carried out by the YOLOv8 (You Only Look Once, version 8) software. In the comparison of histograms, the Hellinger Distance method will be used, employing the Bhattacharyya coefficient to verify if the distance corresponds to the possibility of a vehicle being the same along a specific route. The main objective of the proposed work is to provide an alternative solution to those currently available in the market, such as the ByteTrack tracking method present in the YOLOv8 software, which may result in a possible solution for comparison with others. Vehicle tracking in traffic offers a range of benefits, from increased security by enabling quick location in case of theft to the ability to monitor routes and delivery times, improving the efficiency of logistical operations.

Key-words: Vehicle Tracking. Neural Networks. Histogram Analysis. YOLOv8. Hellinger Distance. Bhattacharyya Coefficient.

LISTA DE FIGURAS

Figura 1 – Exemplo da detecção de objetos em um único animal e em múltiplos animais, exibindo as técnicas de classificação, localização, detecção e segmentação dos objetos.	14
Figura 2 – Demonstração de um Neurônio Natural	15
Figura 3 – Demonstração de um Neurônio Artificial	16
Figura 4 – Diferentes arquiteturas que uma Rede Neural pode assumir	17
Figura 5 – Exemplo de um Sistema de Visão Artificial e suas etapas	18
Figura 6 – Exemplo de um processamento de imagens convencional.	19
Figura 7 – Exemplo do sistema de detecção de objetos do software YOLO. O sistema ajusta a imagem no formato para a detecção (448x448), executa uma única rede convolucional na imagem e exibe os limitantes do resultado da detecção com base na probabilidade do modelo proposto.	20
Figura 8 – Exemplo das detecções realizadas pelo Bytetrack, exibindo as caixas de detecções com suas determinadas pontuações.	21
Figura 9 – Histograma de uma imagem em uma escala de cinza com tons mais escuros.	22
Figura 10 – Histograma de uma imagem em uma escala de cinza com tons de menor variabilidade.	22
Figura 11 – Histograma de frequência por bins de uma imagem colorida.	23
Figura 12 – Exemplo de histogramas similares (acima) e histogramas sem semelhanças (abaixo).	24
Figura 13 – Exemplo da detecção de objetos em movimento através da análise de histogramas.	24
Figura 14 – Imagem base de veículos em tempo aberto no período diurno	32
Figura 15 – Exemplo de detecção de veículos utilizando o YOLOv8.	32
Figura 16 – Exemplo de rastreamento de veículos utilizando o YOLO através do ByteTrack, onde podemos ver um ID sendo associado para cada veículo detectado.	33
Figura 17 – Histograma gerado do veículo de ID igual a 1.	34
Figura 18 – Histograma gerado do veículo de ID igual a 2.	35
Figura 19 – Histograma gerado do veículo de ID igual a 3.	35

1 INTRODUÇÃO

Sugestão de alterar por registrou.
Usar uma linguagem mais formal.

Nos dias atuais, é notável que o Brasil continua a enfrentar desafios significativos relacionados ao furto e roubo de veículos, especialmente nos grandes centros urbanos, impactando não apenas a propriedade individual mas também ameaçando a segurança pública. Durante o primeiro semestre de 2023, o estado de São Paulo **testemunhou** mais de 65 mil incidentes de roubos e furtos de veículos, equivalendo a uma média de 15 casos por hora. Um aspecto alarmante destacado pelos dados é a proporção relativamente baixa de veículos recuperados pelas autoridades policiais. Nesse período, apenas 23.060 veículos foram recuperados, representando aproximadamente um terço (35%) do total perdido por meio de furto ou roubo (VELASCO et al., 2023).

O cenário atual da localização e rastreamento de veículos no trânsito é marcado por avanços tecnológicos significativos nos últimos anos, os quais têm proporcionado grandes melhorias na eficiência e na segurança operacional. No entanto, ainda existem desafios e limitações que motivam a busca por abordagens mais inovadoras e aprimoradas. Os principais deles estão associados à complexidade e dinamismo do ambiente em que os veículos operam, como condições climáticas adversas, tráfego intenso e oclusões ou obstruções que possam vir a transpor os veículos em imagens de trânsito.

A crescente complexidade e demanda por sistemas eficientes de rastreamento e localização de veículos têm impulsionado a pesquisa e desenvolvimento de tecnologias inovadoras que transcendam as limitações tradicionais. A metodologia adotada neste estudo envolve a utilização do software *You Only Look Once* (YOLO) (REDMON et al., 2016) como uma estratégia inovadora para a detecção de veículos, contribuindo para a agilidade e dinamismo necessários dentro destes ambientes dinâmicos, sendo uma ferramenta essencial para fundamentarmos a ideia deste trabalho.

O presente estudo propõe o desenvolvimento de um método para o rastreamento e localização de veículos, fundamentado na análise de imagens de trânsito por meio de técnicas de processamento de imagens e redes neurais. A abordagem adotada baseia-se na avaliação e comparação de histogramas de cores, visando classificar e identificar padrões em sequências de imagens de rastreamento geradas pelo software YOLOv8 (You Only Look Once, versão 8). A comparação dos histogramas será conduzida utilizando o método da Distância de Hellinger relacionado ao Coeficiente de Bhattacharyya, permitindo verificar a consistência da distância em relação à possibilidade de um veículo ser o mesmo ao longo de um trajeto específico.

O propósito principal deste trabalho é apresentar uma alternativa sólida e precisa em relação às soluções já disponíveis no mercado, incluindo métodos de rastreamento como o *ByteTrack* (ZHANG et al., 2022), incorporados no software YOLOv8. A expectativa é que essa abordagem possa resultar em uma solução alternativa e possivelmente comparável às demais existentes, proporcionando benefícios desde o reforço da segurança com a rápida localização em casos de roubo até a capacidade de monitorar rotas e tempos de entrega,

contribuindo assim para a otimização de operações logísticas.

Ao combinar o **poder** da visão computacional e das redes neurais, a relevância prática desta pesquisa é evidente na sua capacidade de contribuir para a otimização de sistemas de rastreamento e localização de veículos, fornecendo uma solução que abrange técnicas modernas de detecção de objetos aliadas com métodos eficazes de reconhecimento de imagens. A aplicação concreta dessas técnicas avançadas não apenas potencializa a segurança e a eficiência no gerenciamento de frotas, mas também abre novas possibilidades para a automação e aprimoramento dos sistemas de transporte.

1.1 Objetivos

1.1.1 Objetivo geral

Desenvolver um método de rastreamento e localização de veículos através da avaliação e comparação de histogramas de cores, visando classificar e identificar padrões em sequências de imagens de rastreamento geradas pelo software YOLOv8. A comparação dos histogramas será conduzida utilizando o método da Distância de Hellinger relacionado ao Coeficiente de Bhattacharyya, permitindo verificar a consistência da distância em relação à possibilidade de um veículo ser o mesmo ao longo de um trajeto específico.

1.1.2 Objetivos específicos

1. Validação da metodologia usando uma base de dados para teste.
2. Avaliar a precisão e a eficiência do método desenvolvido.
3. Comparação do método apresentado com o método de rastreamento ByteTrack utilizado pelo YOLOv8.
4. Avaliação da consistência da Distância de Hellinger utilizando coeficiente de Bhattacharyya.
5. Testar o método de **rastreamento e localização** de veículos apresentado em **condições variadas**. *Essa ordem faz diferença. Então sugiro permutar.*
6. Otimizar o método desenvolvido com base nos resultados dos testes.

2 FUNDAMENTAÇÃO TEÓRICA

A evolução dos métodos de rastreamento por detecção na vigilância por vídeo e o desenvolvimento de ferramentas para a análise automática de dados de vídeo incentivam pesquisas no campo do tráfego rodoviário, as quais apresentam objetivos como a avaliação das demandas atuais e futuras de gestão de tráfego, o desenvolvimento e manutenção de infraestrutura rodoviária e o monitoramento contínuo das estradas. As tecnologias de câmeras e análise automática de vídeo nas rodovias envolvem a instalação de Sistemas de Transporte Inteligentes (ITS) nas margens das estradas visando processar informações de tráfego de forma automática e eficiente. Tais tecnologias são predominantemente baseadas no reconhecimento e rastreamento de objetos em movimento no tráfego, com o intuito de identificar acidentes e congestionamentos, analisar o comportamento dos objetos e fornecer uma descrição da fluidez do tráfego. No entanto, as cenas de tráfego apresentam certas restrições, como diferentes condições de iluminação, categorias de veículos, intensidade tráfego e os mais variados tipos de infraestruturas rodoviárias. Diante dessas restrições, a análise das imagens se torna uma tarefa complexa e limitam o desempenho de soluções utilizadas para processar cenas de tráfego intenso ou de condições adversas. (OTHMANI, 2022). *Parágrafos muito longos e com as mesmas palavras tornam o mesmo confuso.*

2.1 Detecção de objetos

A detecção de objetos emerge como um desafio crucial no campo da visão computacional, originando amplo interesse devido à integração de diversas sub-tarefas que capacitam a extração de informações de imagens e vídeos. Nesse contexto, o propósito fundamental da detecção de objetos se baseia na identificação da posição dos elementos em uma imagem através da criação de caixas delimitadoras (*bounding boxes*), atribuindo a cada uma delas uma categoria específica, englobando tanto sua localização quanto classificação (ZHAO et al., 2019).

Os principais desafios na detecção de objetos incluem: (i) A ocupação de um objeto em uma imagem apresenta uma variação inerente, como objetos em uma imagem que podem ocupar a maioria dos pixels, ou seja, 70% a 80%, ou muito poucos pixels, ou seja, 10% ou até menos, (ii) Processamento de conteúdos visuais de baixa resolução, (iii) Lidar com objetos múltiplos de tamanhos variados em uma imagem, (iv) Disponibilidade de dados rotulados e (v) Lidar com sobreposição de objetos em conteúdo visual (DIWAN; ANIRUDH; TEMBHURNE, 2023).

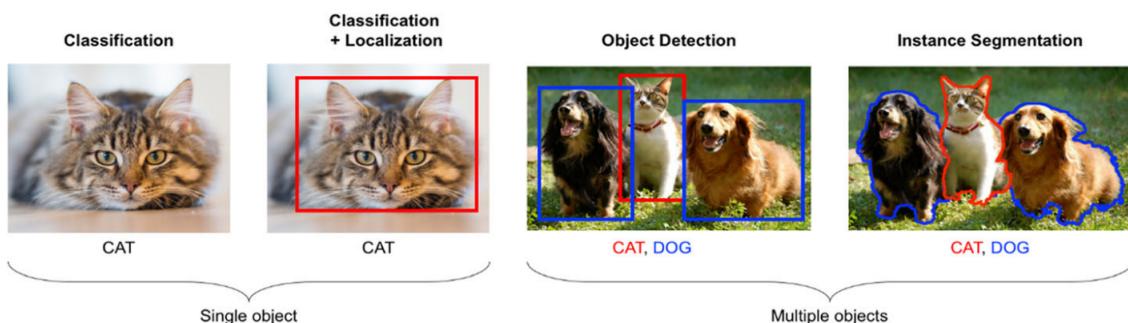
Encontrar um ponto ideal entre a precisão e o custo computacional em modelos de detecção é uma tarefa complexa, pois varia significativamente de acordo com o propósito específico de cada implementação. Quando nos voltamos para a detecção de veículos em cenários reais de tráfego, deparamo-nos com desafios notáveis. O fenômeno de oclusões, onde um veículo pode ocultar parcial ou completamente outro, torna-se uma complicação relevante. Além disso, as variações de escala e rotação que surgem quando os veículos se

deslocam ao longo da perspectiva da câmera, juntamente com alterações na iluminação provocadas por fatores ambientais como sombras e reflexos, acrescentam complexidade ao processo de detecção. Essas nuances exemplificam a necessidade de abordagens personalizadas e adaptáveis para lidar eficazmente com os desafios específicos apresentados pela detecção de veículos em ambientes dinâmicos (ERAZO et al., 2021).

De modo geral, os detectores de objetos são divididos em duas categorias: detectores de **duas etapas**, os quais têm como foco principal a estratégia de propostas de região seletiva por meio de uma arquitetura **complexa**; e detectores de **uma etapa**, os quais concentram-se em todas as propostas de região espacial para a detecção potencial de objetos, utilizando uma arquitetura relativamente mais simples em uma única iteração. Anteriormente, os detectores de objetos em duas etapas eram amplamente adotados e eficazes. No entanto, devido aos recentes avanços na detecção de objetos em uma única etapa e nos algoritmos associados, houve uma melhoria significativa em relação à maioria dos detectores de objetos em duas etapas. Além disso, a introdução do YOLO (You Only Look Once) (REDMON et al., 2016), um detector de objetos de etapa única levou diversas aplicações a empregar essa abordagem para detecção e reconhecimento de objetos em diferentes contextos, demonstrando um desempenho notavelmente superior quando comparado aos detectores de dois estágios correspondentes. Nesse contexto, a detecção de objetos pode ser vista como a integração de processos de classificação, localização e segmentação, envolvendo a correta atribuição de classes e a determinação da localização de um ou vários objetos em uma imagem, tipicamente por meio de algoritmos supervisionados. A Figura 1 oferece uma representação clara dos conceitos de classificação, localização e segmentação aplicados a objetos únicos e múltiplos em uma imagem, no âmbito da detecção de objetos. (DIWAN; ANIRUDH; TEMBHURNE, 2023).

Figura 1 – Exemplo da detecção de objetos em um único animal e em múltiplos animais, exibindo as técnicas de classificação, localização, detecção e segmentação dos objetos.

Acho que parte da figura 1 está fora do contexto do texto acima, pois se falou da detecção de objetos de uma e duas etapas. Uma figura que exemplifique o que foi dito no texto pode ser melhor.



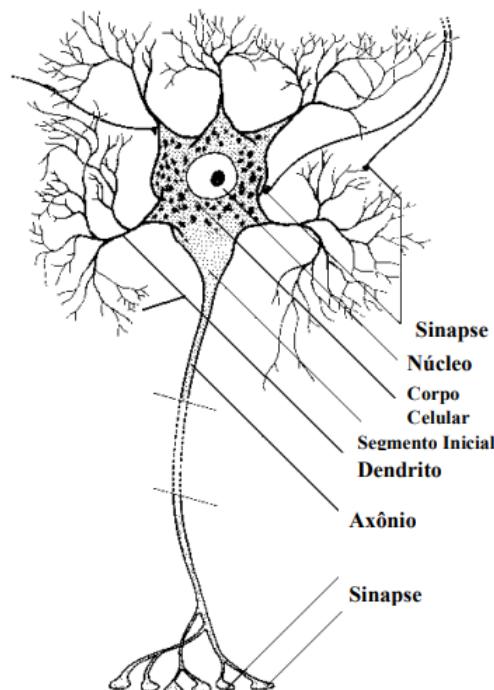
Fonte: (DIWAN; ANIRUDH; TEMBHURNE, 2023)

2.2 Redes Neurais

O desafio do reconhecimento e caracterização de objetos em imagens tem demandado notável dedicação ao longo do tempo. Inicialmente, até a década de 70, as técnicas ópticas de processamento eram preponderantes, mas a partir dos anos 80, com os avanços na microeletrônica e no desenvolvimento de arquiteturas paralelas de processamento, houve uma transição significativa para o uso mais abrangente de técnicas digitais. O amadurecimento das técnicas computacionais inteligentes como as Redes Neurais, introduziu novas abordagens para enfrentar esse desafio. A crescente complexidade do problema de reconhecimento e classificação de imagens, dificilmente tratável em termos algorítmicos, tem propiciado o aumento substancial do uso dessas técnicas, em especial as Redes Neurais Artificiais (RNAs) (LIBERMAN, 1997).

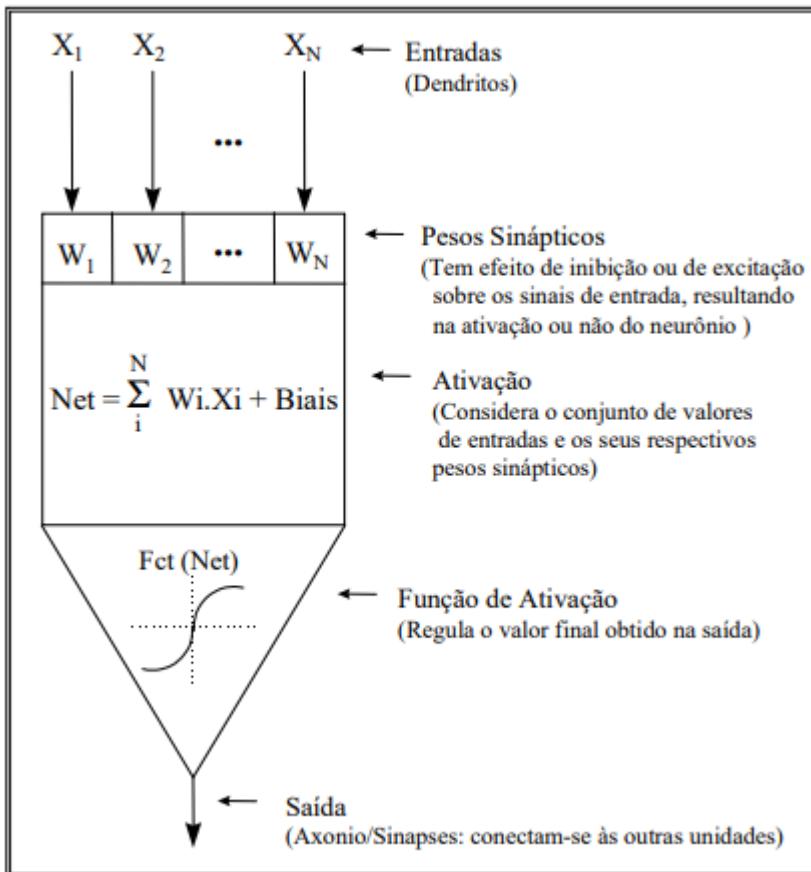
A estrutura de uma Rede Neural Artificial (RNA) codifica seu conhecimento, com destaque para as conexões, ou sinapses, entre suas unidades constituintes, os neurônios. Em tais redes simuladas por computadores, cada conexão é associada a um peso sináptico - um valor numérico que indica a força da conexão entre dois neurônios. O aprendizado em uma RNA ocorre através de um processo de adaptação desses pesos sinápticos. As Figuras 2 e 3 ilustram a relação entre os neurônios naturais e o modelo de neurônio artificial (OSÓRIO; BITTENCOURT, 2000).

Figura 2 – Demonstração de um Neurônio Natural

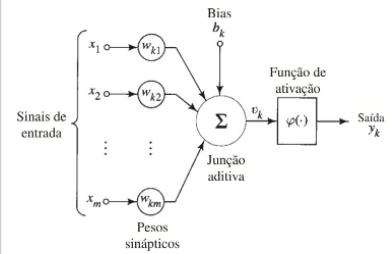


Fonte: (OSÓRIO; BITTENCOURT, 2000)

Figura 3 – **Demonstração** de um Neurônio Artificial
Exemplo de um neurônio artificial.



Sugiro deixar apenas a figura do neurônio e descrever cara parte no texto. Há outras imagens na literatura mais ilustrativas.



O livro clássico Redes Neurais: Princípios e Prática do Simon Haykin poderia ser usado.

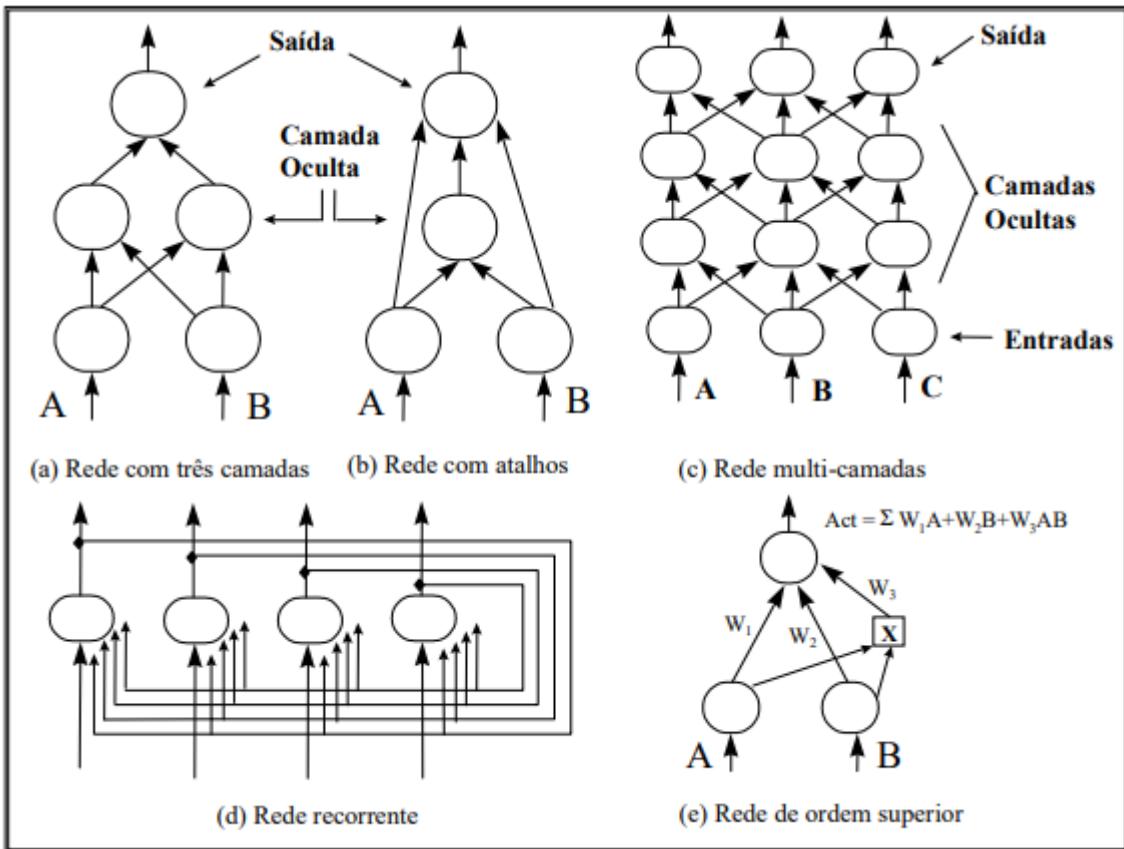
Fonte: (OSÓRIO; BITTENCOURT, 2000)

As Redes Neurais, consideradas dispositivos não-lineares inspirados na funcionalidade dos neurônios biológicos, são empregadas no reconhecimento de padrões, otimização e previsão de sistemas complexos. A capacidade dessas redes em formar mapeamentos não-lineares as torna especialmente eficazes nessas aplicações. Uma rede neural é composta por inúmeras unidades computacionais paralelas interconectadas, denominadas neurônios artificiais. Cada neurônio é responsável por executar um número de operações simples e transmitir os resultados aos neurônios vizinhos, aos quais está conectado. Por meio de um processo de treinamento, as redes neurais adquirem a habilidade de identificar padrões, mesmo diante de dados de treinamento não-lineares, incompletos ou contraditórios. A aptidão para lidar com informações imprecisas confere às redes neurais uma eficácia significativa em tarefas onde a expertise de especialistas é limitada ou em contextos nos quais a formulação de um conjunto de regras é uma tarefa desafiadora (LIBERMAN, 1997).

Várias maneiras de interconectar as unidades de uma Rede Neural Artificial (RNA) são propostas, resultando em diversas arquiteturas. A Figura 4 ilustra alguns exemplos

dessas possíveis configurações. As arquiteturas mais significativas incluem redes de camada única, redes de camadas unidirecionais e redes recorrentes (OSÓRIO; BITTENCOURT, 2000).

Figura 4 – Diferentes arquiteturas que uma Rede Neural pode assumir



Fonte: (OSÓRIO; BITTENCOURT, 2000)

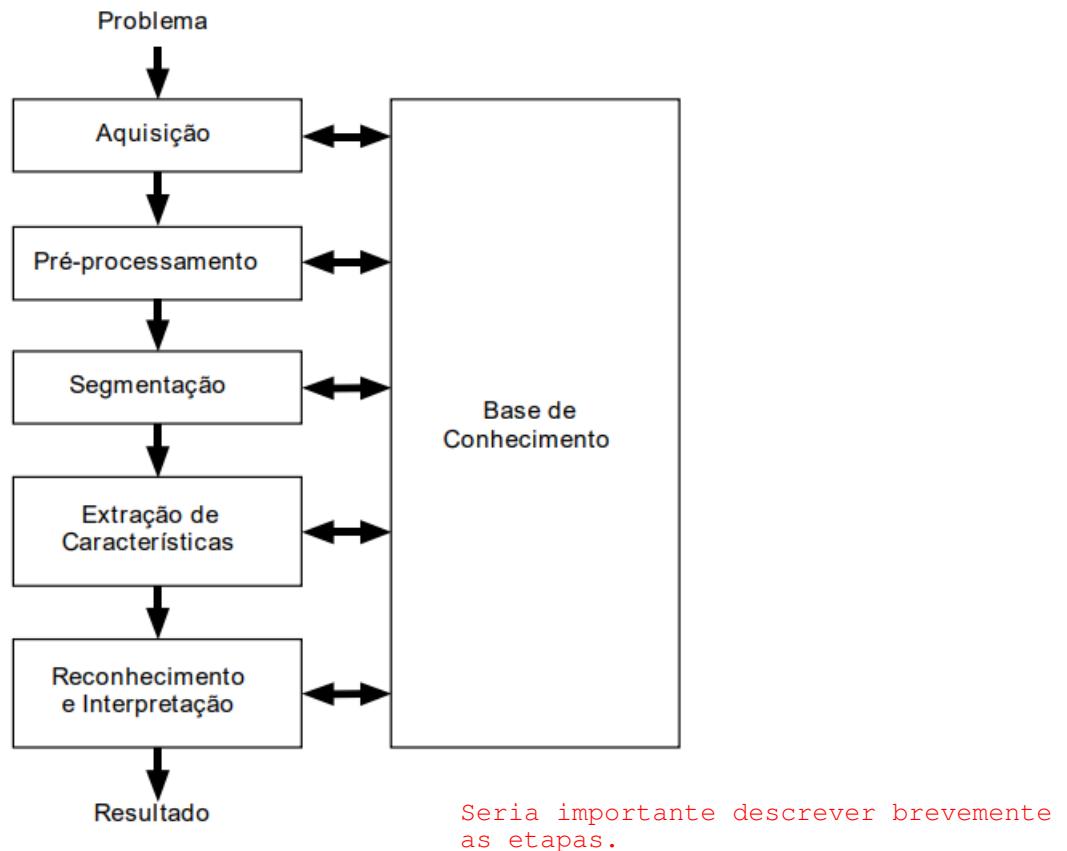
Como alternativa aos sistemas tradicionais de inteligência artificial, as Redes Neurais têm se destacado em diversas aplicações, sendo uma das principais o reconhecimento de padrões. Nesse contexto, o reconhecimento de padrões refere-se à identificação ou classificação de medidas de informação em categorias, as quais representam entidades ou padrões com características similares. Esse domínio abrange uma variedade de abordagens integradas para resolver problemas práticos e as imagens digitais desempenham um papel central nessa área de pesquisa (LIBERMAN, 1997).

2.3 Processamento de Imagens

A área de processamento de imagens tem atraído cada vez mais atenção devido à sua capacidade de possibilitar uma ampla gama de aplicações em duas categorias principais: o aperfeiçoamento de informações visuais para interpretação humana e a análise

computacional automática de informações obtidas de uma cena. Desde 1964 até o presente, esse ramo tem experimentado um crescimento notável e suas aplicações abrangem quase todos os aspectos da vida humana, envolvendo processos geralmente expressos de forma algorítmica. Por causa disso, com exceção das fases de aquisição e exibição, a maioria das funções de processamento de imagens pode ser implementada por meio de software. No processamento de imagens, um Sistema de Visão Artificial (SVA) é definido como um sistema computadorizado capaz de adquirir, processar e interpretar imagens que representam cenas reais (FILHO; NETO, 1999). A figura 5 apresenta um diagrama de blocos de um SVA de forma esquemática.

Figura 5 – Exemplo de um Sistema de Visão Artificial e suas etapas



Fonte: (FILHO; NETO, 1999)

O processo de extração de objetos móveis em primeiro plano de uma imagem ou de uma série de imagens é chamado de subtração de fundo. Após esse processo, as informações extraídas são apresentadas como o limiar da diferença entre imagens. Este método é amplamente utilizado na detecção de regiões de veículos como parte dos métodos de detecção de mudanças. Uma desvantagem notável é a falta de adaptabilidade, que surge devido às mudanças nas condições de iluminação e climáticas (VASU, 2010).

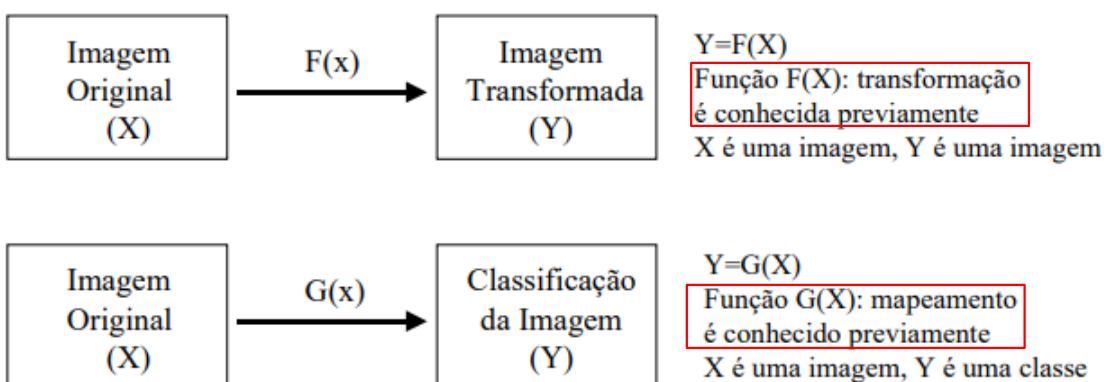
De acordo com Osório (OSÓRIO; BITTENCOURT, 2000), o processamento de

imagens se divide em duas áreas principais de trabalho:

1. Tratamento de Imagens: Nesta área, uma imagem original é transformada para criar uma versão modificada. As principais funções de manipulação de imagem incluem aprimorar ou restaurar elementos de uma imagem (destaque dos contornos dos objetos), modificar seus componentes (conversão de uma imagem colorida para normalmente para escala de cinza e para preto/branco), preto e branco ou aplicação de efeitos especiais) e corrigir distorções (melhoria do foco de uma imagem que não está clara). Aplicação de filtros de suavização, de realce, etc.
2. Reconhecimento de padrões: Nesta área, um processamento é realizado na imagem original para analisá-la e identificar seus componentes. Este processo permite extrair uma descrição de alto nível de seus componentes, agrupar os componentes que são semelhantes ou classificar seus componentes em grupos predefinidos.

A Figura 6 retrata as funções de um processamento de imagens convencional, usado para implementar através de algoritmos as funções matemáticas responsáveis pelas análises e transformações das imagens. Melhorar a escrita do parágrafo para deixar claro o que faz a figura 6.

Figura 6 – Exemplo de um processamento de imagens convencional.



Fonte: (OSÓRIO; BITTENCOURT, 2000)

2.4 Software YOLO (You Only Look Once)

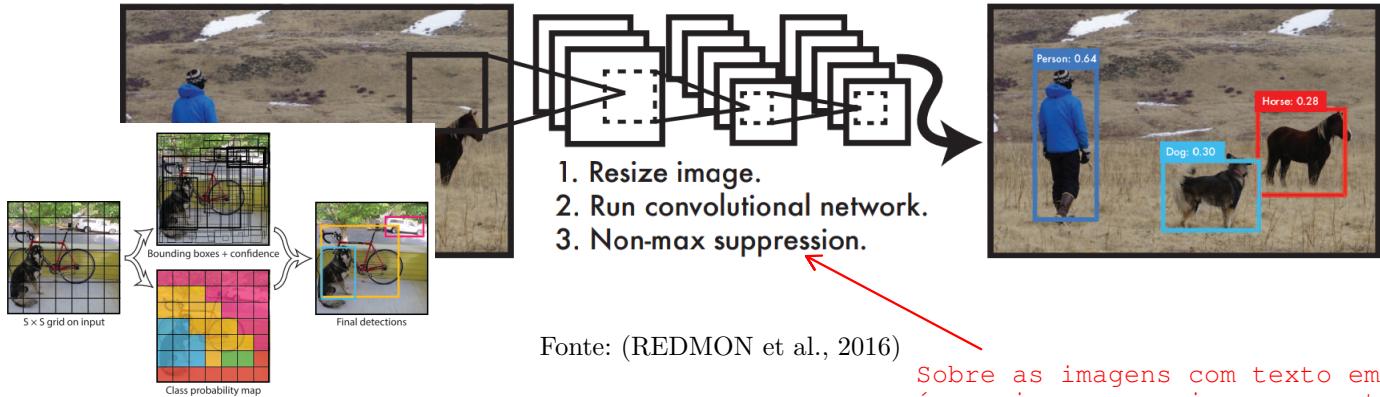
Na atualidade, os sistemas de detecção existentes no mercado geralmente reaproveitam classificadores para realizar a tarefa de detecção, utilizando um classificador específico para um objeto e o avaliando em várias localizações e escalas em uma imagem de teste. Abordagens mais recentes, como Redes Convolucionais Baseadas em Regiões (R-CNN) (GIRSHICK et al., 2015), utilizam métodos para inicialmente gerar potenciais caixas delimitadoras em uma imagem e, em seguida, aplicar um classificador a essas caixas propostas (algoritmo de detecção de duas etapas). No entanto, esses pipelines complexos

ok

O que significam esses componentes?

acabam se tornando lentos e desafiadores de otimizar, em razão de que cada componente individual deve ser treinado separadamente. Por outro lado, o sistema YOLO (*You Only Look Once*) (REDMON et al., 2016), conta com um método mais simplificado e eficaz, reformulando a detecção de objetos como um único problema de regressão, ou seja, uma única rede convolucional prevê simultaneamente múltiplas caixas delimitadoras e probabilidades de classe para essas caixas (algoritmo de detecção de uma etapa). Tal modelo unificado oferece diversas vantagens em relação aos métodos tradicionais de detecção de objetos, principalmente pelo fato do YOLO trabalhar a detecção como um problema de regressão, eliminando a necessidade de um pipeline, otimizando todo o processo. A Figura 7 exemplifica o processo da detecção de objetos com o YOLO, tecnologia que alcança mais que o dobro da média de precisão em comparação com outros sistemas em tempo real (REDMON et al., 2016). *Como o trabalho original é de 2016, atualmente esses dados não conferem. Revisar a literatura.*

Figura 7 – Exemplo do sistema de detecção de objetos do software YOLO. O sistema ajusta a imagem no formato para a detecção (448x448), executa uma única rede convolucional na imagem e exibe os limitantes do resultado da detecção com base na probabilidade do modelo proposto. *Reescrever essa parte pois a imagem é usada como entrada para a rede e em uma única passagem realiza o processo de detecção.*



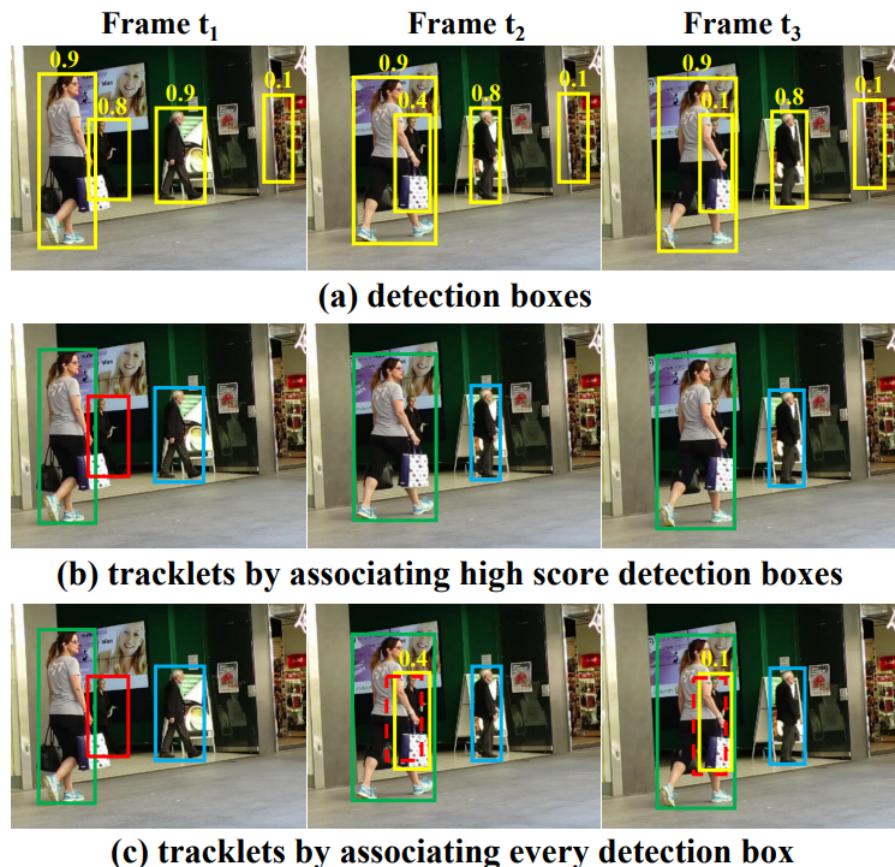
Ver nota no parecer sobre essa imagem e sobre a Yolo.

2.4.1 Bytetrack

Atualmente, o paradigma de rastreamento por detecção é o mais eficiente para o rastreamento de múltiplos objetos. Contudo, em cenários complexos presentes em vídeos, os detectores podem gerar previsões que não são perfeitas. As caixas de detecção de baixa pontuação (com baixa probabilidade de acerto) podem, em algumas ocasiões, sinalizar a presença de objetos que estão oclusos nas imagens para detecção. Com o objetivo de aproveitar ao máximo as caixas de detecção, desde as de alta até as de baixa pontuação no processo de correspondência, Zhang (ZHANG et al.,) apresenta um método de associação chamado BYTE, que é simples e eficaz, onde inicialmente é realizada a correspondência das caixas de detecção de alta pontuação com os rastros com base na semelhança de movimento ou aparência. O BYTE pode ser facilmente incorporado a rastreadores já existentes, proporcionando melhorias consistentes. Para contribuir com o avanço da área

de rastreamento de múltiplos objetos, o autor propõe um rastreador simples e de alta precisão, chamado ByteTrack. O ByteTrack se apresenta muito eficaz em relação à ocluções, graças ao seu desempenho preciso de detecção e à ajuda da associação de caixas de detecção de baixa pontuação. Tal tecnologia também se destaca em como otimizar o uso dos resultados de detecção para aprimorar o rastreamento de múltiplos objetos. A alta precisão, velocidade e a simplicidade do ByteTrack são características que tornam um método de rastreamento poderoso para aplicações reais. A Figura 8 apresenta um exemplo da detecção realizada pelo Bytetrack.

Figura 8 – Exemplo das detecções realizadas pelo Bytetrack, exibindo as caixas de detecções com suas determinadas pontuações.



Fonte: (ZHANG et al.,)

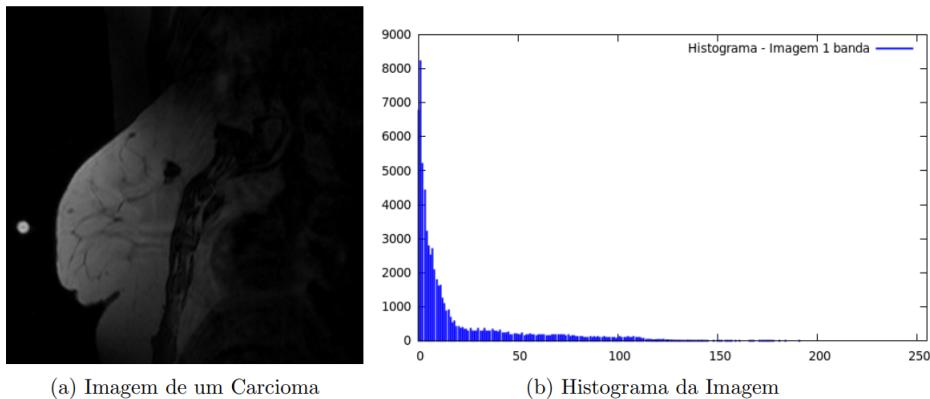
falta o ano?

2.5 Histogramas de cores

O histograma é uma representação gráfica que revela a frequência dos valores de brilho presentes em uma imagem, refletindo a intensidade luminosa na cena capturada. Analisando a Figura 9, observamos que a maioria dos pixels concentra-se em valores **valores de intensidade**

mais baixos no eixo x do histograma, indicando uma predominância de pixels escuros em relação aos claros (MARTINS, 2016).

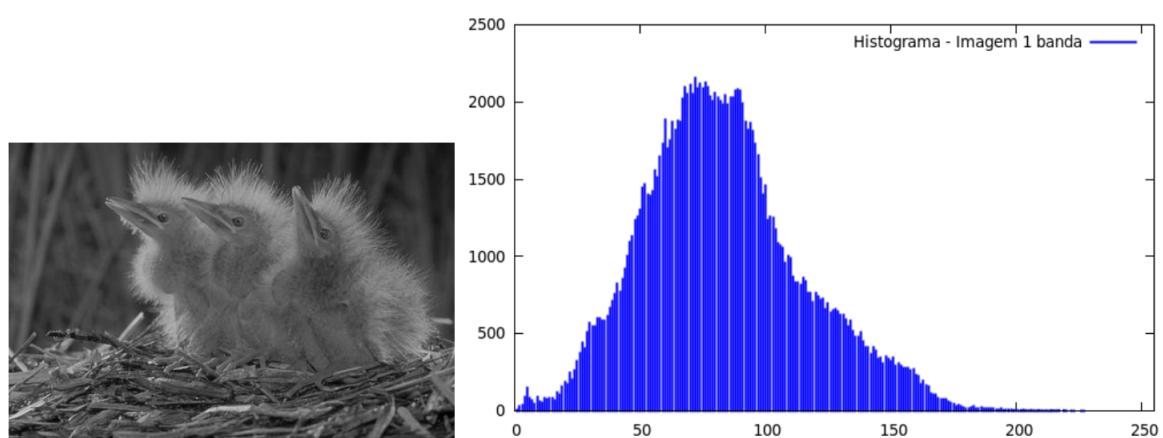
Figura 9 – Histograma de uma imagem em uma escala de cinza com tons mais escuros.



Fonte: (MARTINS, 2016)

Contrastando com a Figura 10, seu histograma revela uma distribuição mais centralizada dos pixels na escala de cinza. Isso sugere que a imagem possui uma variedade maior de tons cinza, abrangendo diversas intensidades, proporcionando uma representação mais equilibrada em termos de brilho (MARTINS, 2016).

Figura 10 – Histograma de uma imagem em uma escala de cinza com tons de menor variabilidade.



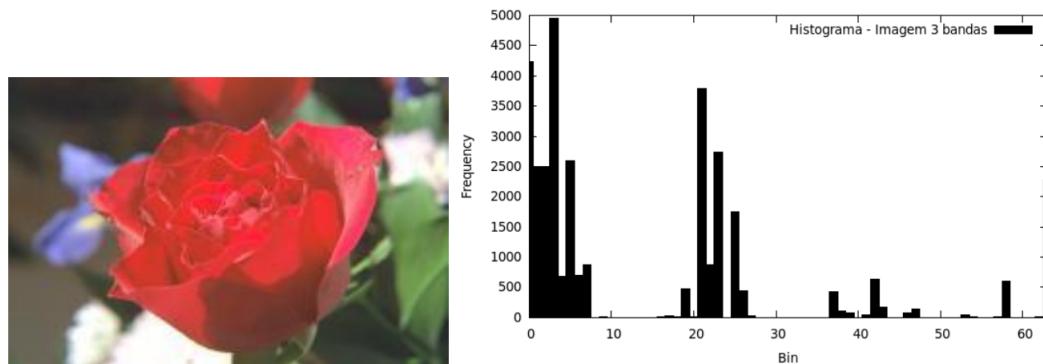
Fonte: (MARTINS, 2016)

Dizer o que significa bins. Mencionar brevemente que são intervalos que exibem a frequência de valores dentro desse intervalo/bin.

Ao considerar imagens coloridas, a Figura 11 apresenta um histograma de frequência por bins. No caso desta imagem de 8 bits, cada pixel possui valores para as camadas RGB variando de 0 a 255. O histograma, calculado com 64 bins, destaca: Bins 0 a 3: bins

exclusivamente valores da camada R; Bins 4 a 15: valores de R e G; Bins 16 a 63: valores de R, G e B.

Figura 11 – Histograma de frequência por bins de uma imagem colorida.



Fonte: (MARTINS, 2016)

Os bins 0 representam os tons mais escuros, enquanto os bins 63 indicam os tons mais claros. A análise da soma dos bins revela que a camada R abrange valores de 0 a 3, a camada G varia de 4 a 12, e a camada B se estende de 16 a 48. O detalhamento do histograma apresentado proporciona uma compreensão abrangente da distribuição de cores da imagem colorida em questão (MARTINS, 2016).

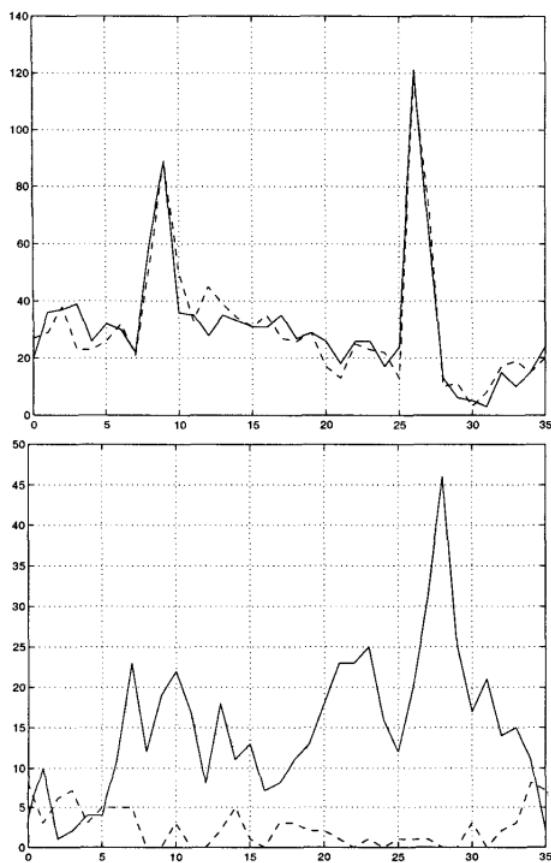
Em termos técnicos, um histograma de cores se trata essencialmente de um vetor no qual cada componente registra a quantidade de pixels correspondentes a uma cor específica na imagem. Antes de serem submetidas à criação do histograma, todas as imagens passam por um processo de dimensionamento para garantir a uniformidade no número de pixels. Além disso, as cores da imagem são convertidas para um espaço de cores discreto composto por n tonalidades. De maneira típica, as imagens são retratadas no espaço de cores RGB, onde são utilizados alguns dos bits mais significativos em cada canal de cor para discretizar eficientemente o espaço de cores (PASS; ZABIH, 1999).

Se a imgem for redimensionada, certamente haverão perdas e erros no processo de criação do histograma.

2.5.1 Histogramas de cores na detecção de objetos

Vários pesquisadores desenvolveram abordagens para identificar indivíduos em imagens, a maioria das quais se fundamenta na subtração de fundo utilizando dados de cor ou luminância. Os resultados comumente enfrentam desafios relacionados a falsos positivos ou negativos, demandando etapas de pós-processamento adicionais para eliminar objetos ou lacunas não autênticos. As técnicas que se apoiam em histogramas para a detecção e acompanhamento de objetos em vídeos destacam-se por sua rapidez, confiabilidade e pela dispensa de um treinamento prévio extensivo para "aprender" o modelo do fundo (MASON; DURIC, 2001). A Figura 12 exemplifica a diferenciação de histogramas e a Figura 13 exibe um exemplo de uma detecção através da análise de histogramas.

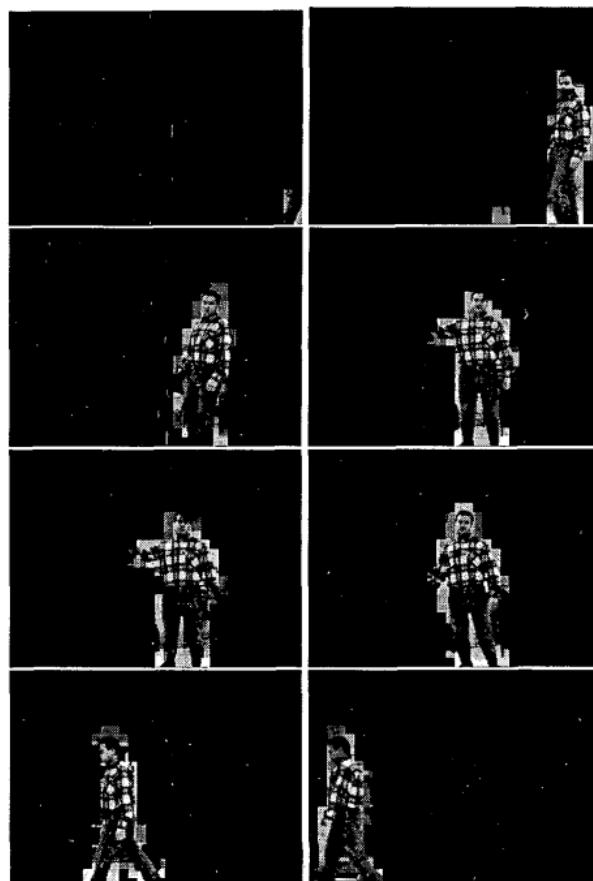
Figura 12 – Exemplo de histogramas similares (acima) e histogramas sem semelhanças (abaixo).



Fonte: (MASON; DURIC, 2001)

Esclarecer o que significa a linha contínua e a linha tracejada nas imagens. Ademais, seria interessante colocar a sequência com alguns frames referentes ao histograma e a detecção dos objetos para melhor entendimento.

Figura 13 – Exemplo da detecção de objetos em movimento através da análise de histogramas.



Fonte: (MASON; DURIC, 2001)

[Ver nota no parecer.](#)

2.6 Distância de Hellinger com Coeficiente de Bhattacharyya

No campo da probabilidade e estatística, a Distância de Hellinger (HELLINGER, 1909) se apresenta como uma medida de similaridade entre duas distribuições de probabilidade, sendo definida em termos da Integral de Hellinger ([WIKIPEDIA, 2023c](#)). Para entendermos melhor o funcionamento desta métrica, podemos considerar duas distribuições de probabilidade, P e Q, definidas sobre o mesmo espaço de probabilidade. A distância de Hellinger varia de 0 a 1, sendo 0 indicativo de que as distribuições são idênticas, e 1 indicativo de que são completamente diferentes. A métrica atinge o valor máximo de 1 quando a probabilidade atribuída por P é zero para cada conjunto ao qual Q atribui uma probabilidade positiva, e vice-versa. A Distância de Hellinger está diretamente relacio-

citar outra fonte, como um artigo ou livro

nada ao Coeficiente de Bhattacharyya (WIKIPEDIA, 2023a) entre as distribuições P e Q. O coeficiente de Bhattacharyya (BC) mede a sobreposição entre as distribuições e é calculado como a raiz quadrada da complementaridade entre elas. A Equação 2.1 apresenta a fórmula da relação entre a Distância de Hellinger (H) e o coeficiente de Bhattacharyya (BC) sobre as distribuições P e Q.

$$H(P, Q) = \sqrt{1 - BC(P, Q)} \quad (2.1)$$

Fonte: (WIKIPEDIA, 2023b)

citar outra fonte, como um artigo ou livro

Falta apresentar o coeficiente BC

Página em branco.

3 REVISÃO BIBLIOGRÁFICA

Com o crescimento do número de veículos, a incidência de roubos e furtos também aumenta. Sousa (SOUZA, 2013) propõe a criação de um sistema web que permita a qualquer pessoa com acesso à Internet e um dispositivo de rastreamento GPS registrado no sistema, localizar seu veículo. O Sistema de Posicionamento Global (GPS), desenvolvido pelo Departamento de Defesa dos Estados Unidos para uso militar, é amplamente utilizado em diversas aplicações civis. O GPS opera com 24 satélites, distribuídos em seis órbitas diferentes a cerca de 20.200 km da superfície terrestre, garantindo que pelo menos quatro estejam visíveis em qualquer ponto do planeta. O método proposto envolve o desenvolvimento de um sistema onde um ou mais rastreadores GPS são registrados e associados a um veículo e seus usuários. Após o registro, todos os usuários vinculados ao proprietário do veículo podem acessar o sistema e verificar a localização dos veículos. Os resultados obtidos indicam que a integração do sistema com o rastreador GPS é eficaz, desde que a comunicação entre ambos esteja funcionando corretamente. Os testes de registro, rastreamento em tempo real e rastreamento por período foram bem-sucedidos e os dados apresentados ao usuário foram consistentes com os recebidos pelo sistema.

Segundo Montanari (MONTANARI, 2016), a fusão da visão computacional com a robótica móvel tem despertado grande interesse entre os pesquisadores na área de robótica, especialmente na criação de Veículos Aéreos Não Tripulados (UAVs). Tais UAVs têm sido amplamente utilizados em setores como defesa, segurança e agricultura. No Brasil, várias instituições de pesquisa estão focadas em áreas como processamento de imagens e piloto automático para UAVs. O autor informa que seu trabalho é motivado pela necessidade de desenvolver um módulo de rastreamento de objetos em tempo real. O processo envolve a localização e o acompanhamento da posição do objeto na imagem, utilizando sistemas de atenção visual para identificar regiões de interesse e facilitar a identificação de objetos. Sendo assim, a classificação de imagens é empregada para distinguir veículos de outros objetos e métodos de correspondência de imagens são usados para o processo de identificação. O desafio de rastrear veículos usando imagens capturadas por um UAV móvel torna este trabalho importante, desafiador e uma excelente oportunidade de pesquisa.

→ O trabalho de Coifman (COIFMAN et al., 1998) discute a segmentação e o rastreamento de veículos, bem como a determinação de parâmetros de tráfego a partir de dados de rastreamento. O autor argumenta que, ao medir as rotas dos veículos ao longo de um trecho da estrada, é possível obter uma medida mais precisa da densidade do tráfego, em vez de simplesmente registrar a ocupação do veículo detectado. A média dos trajetos no espaço e no tempo resulta em parâmetros de tráfego mais estáveis do que as medições correspondentes dos detectores de ponto, que só podem fazer a média no tempo. O sistema de rastreamento de veículos pode fornecer dados individuais de veículos (como espaçamento, intervalo, velocidade e aceleração), o que pode contribuir para uma modelagem mais precisa do fluxo de tráfego e uma melhor compreensão do comportamento

do motorista. Neste trabalho, o autor apresenta um sistema de detecção e rastreamento de veículos projetado para operar sob essas condições desafiadoras. Em vez de rastrear veículos inteiros, são rastreados recursos de veículos, o que torna o sistema menos sensível ao problema da oclusão parcial. As trajetórias resultantes dos veículos podem ser usadas para fornecer parâmetros de tráfego tradicionais, bem como novas métricas, como mudanças de faixa. As trajetórias podem ser usadas como entrada para aplicações de vigilância automatizadas mais sofisticadas, por exemplo, detecção de incidentes com base em manobras de aceleração/desaceleração e mudança de faixa.

De acordo com Asha (ASHA; NARASIMHADHAN, 2018), com o crescimento do número de vias e veículos, a gestão do tráfego se torna um componente crucial dos sistemas de transporte inteligentes. Diversas pesquisas têm sido desenvolvidas sobre aplicações de controle de tráfego que utilizam técnicas de processamento de imagem e vídeo. A análise de dados de vídeo de tráfego inclui a identificação e reconhecimento de veículos, a medição da velocidade dos veículos, a criação de trajetórias de rastreamento, a contagem de veículos, o congestionamento de tráfego e as colisões de veículos. Com a disponibilidade de câmeras e dispositivos embarcados de baixo custo, essas aplicações têm se tornado cada vez mais populares. O sistema automatizado enfrenta desafios como a presença de sombras, a oclusão de veículos e variações ambientais como chuva e neblina que afetam o desempenho das detecções. A contagem de veículos é geralmente realizada separando os objetos em movimento da parte estática da cena. No método empregado pelos autores, é proposto um método de contagem de veículos baseado em vídeo em imagens de tráfego rodoviário capturado por câmeras portáteis. O processamento de um vídeo é realizado em três etapas: detecção dos objeto por meio de YOLO (You Only Look Once), rastreamento com filtro de correlação e contagem. O YOLO alcançou um resultado notável na área de detecção de objetos, e os filtros de correlação obtiveram maior precisão e velocidade no rastreamento. Assim, é implementado o rastreamento de múltiplos objetos com filtros de correlação usando as caixas delimitadoras geradas pelo software YOLO. Por fim, os experimentos usando sequências de vídeo reais demonstram que o método proposto pode detectar, rastrear e contar os veículos com alta precisão. **Não recomendo usar a palavra software.**

Conforme Mason (MASON; DURIC, 2001), a identificação de indivíduos em imagens é um campo de pesquisa que tem atraído muitos estudiosos. O processo geralmente envolve a criação de um modelo do cenário com base em uma série de imagens, que é então usado para distinguir pixels em novas imagens como pertencentes ao fundo ou ao primeiro plano. No entanto, esses métodos podem resultar em falsos positivos ou negativos, exigindo processamento adicional para eliminar objetos incorretos ou preencher lacunas. No estudo proposto pelo autor, é apresentado uma nova estratégia para a detecção e rastreamento de objetos em movimento, a qual utiliza técnicas de correspondência de histograma para melhorar a precisão e confiabilidade dos resultados, superando algumas das limitações dos métodos de detecção de objetos existentes que se baseiam em cores ou bordas. O

método proposto constrói um modelo de fundo a partir de uma única imagem e pode ser aplicado tanto em câmeras fixas quanto em câmeras móveis, o qual provou ser resistente ao ruído da câmera e a pequenas variações de iluminação, oferecendo uma abordagem precisa para a detecção de objetos em imagens.

Página em branco.

Fazer a citação, já que a 1^a ocorrência
é nesse ponto.

4 METODOLOGIA

A metodologia adotada para detecção e rastreamento de veículos inova ao incorporar o *benchmark* da UA-DETRAC, oferecendo uma rica variedade de imagens de trânsito para avaliação. Utilizando o ~~software~~ YOLOv8 e sua capacidade de detecção de veículos, o presente trabalho propõe um método de rastreamento baseado na comparação de histogramas de cores sobre as detecções geradas pelo YOLO. Através da geração de histogramas sobre as *bounding boxes* (caixas delimitadoras) dos veículos, a análise da Distância de Hellinger utilizando o Coeficiente de Bhattacharyya busca proporcionar uma alternativa de possível comparação com as já presentes na área de rastreamento veicular. Além da descrição da implementação, será apresentado uma comparação das taxas de acerto do método apresentado com o algoritmo ByteTrack, visando fornecer informações sobre sua aplicabilidade e desempenho em comparação com abordagens tradicionais.

Data

Informar qual sequência foi usada.

4.1 Base de dados

- Dataset:
 - DETRAC-Train-Images (5.22GB, 60 sequences)
 - DETRAC-Test-Images (3.94GB, 40 sequences)
- Detections:
 - DETRAC-Train-Detections (DPM, ACF, R-CNN, CompACT)
 - DETRAC-Test-Detections (DPM, ACF, R-CNN, CompACT)

A base de dados do *benchmark* da UA-DETRAC (LYU, 2017) está sendo utilizada para a realização das detecções de veículos, contendo sequências de imagens de trânsito de alta qualidade utilizadas para testes. O *dataset* consiste em *frames* que registram diversos tipos de veículos em estradas, principalmente rodovias. Os tipos de veículos presentes na base de dados incluem desde carros, vans, caminhões, ônibus, bicicletas, motocicletas, veículos com reboques, etc. As imagens são expostas a variações de ambiente de diferentes períodos do dia e condições climáticas.

4.2 Detecção e rastreamento dos veículos através do YOLO

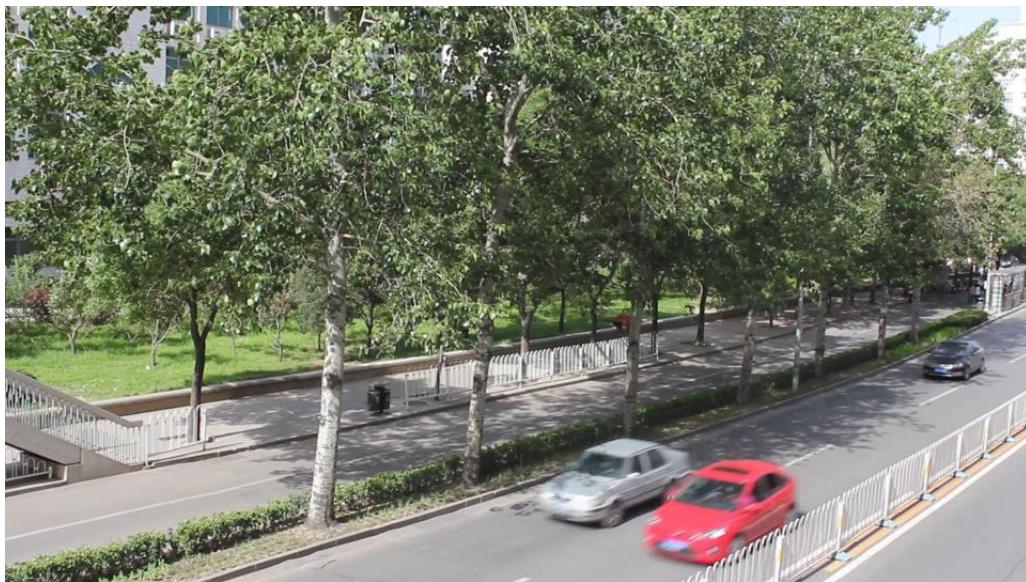
A detecção dos veículos em imagens da base de dados apresentada está sendo realizada através do ~~software~~ YOLO, utilizando o modelo "YOLOv8m" da biblioteca *Ultralytics YOLO* (ULTRALYTICS, 2023). O processo de detecção é realizado através dos seguintes passos:

1. O modelo é carregado a partir do arquivo "yolov8m.pt".
2. É realizada a detecção na imagem de teste especificando o seu caminho, considerando somente as classes de veículos que abrangem: carros, motocicletas, ônibus e caminhões.
3. O resultado da detecção é exibido e salvo.

Consideramos a Figura 14 como imagem base para usarmos no exemplo das detecções e rastreamentos realizados pelo YOLOv8.

Figura 14 – Imagem base de veículos em tempo aberto no período diurno.

retirar espaço



Fonte: (LYU, 2017).

A Figura 15 apresenta um exemplo da detecção de veículos utilizando o YOLOv8 em condições de tempo aberto no período diurno.

Figura 15 – Exemplo de detecção de veículos utilizando o YOLOv8.



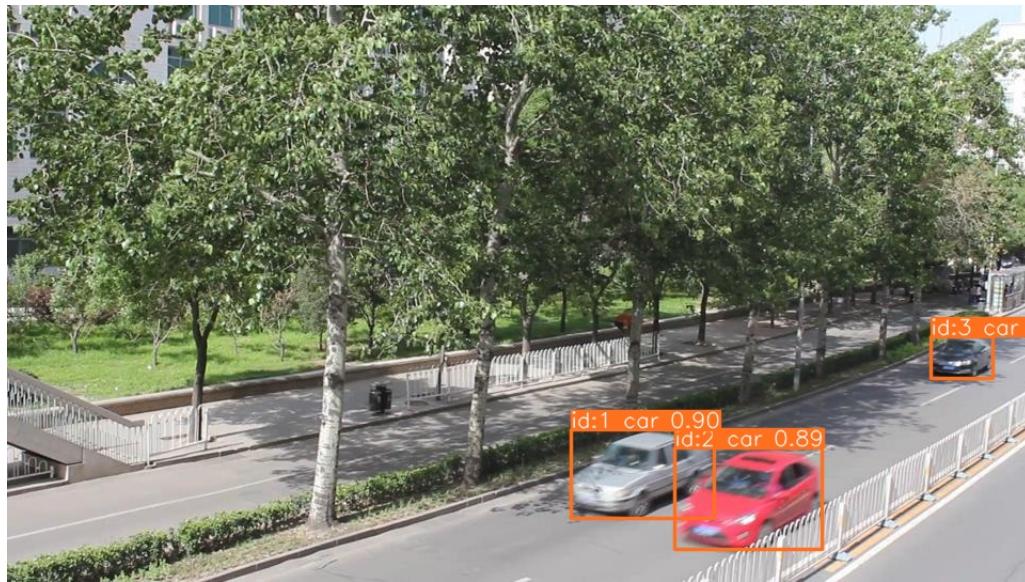
Fonte: Autor.

O YOLO é atualmente composto por apenas dois algoritmos de detecção: BoTSORT e ByteTrack. Para realizar a detecção e rastreamento dos veículos, utiliza-se o

método `track()`, especificando o algoritmo de rastreamento responsável. Tal método rotula cada veículo com seu respectivo "ID"^{inserir espaço} em forma de um número, acompanhando o veículo nos variados ***frames*** (quadros). Como apresentado, a proposta deste trabalho se baseia em apresentar um método de rastreio através da comparação de histogramas das detecções dos veículos, sendo então realizadas comparações diante dos métodos de rastreamento atuais que o YOLO oferece, mais especificamente o algoritmo ByteTrack.

A Figura 16 apresenta um exemplo do rastreamento de veículos utilizando o YOLOv8 em condições de tempo aberto no período diurno.

Figura 16 – Exemplo de rastreamento de veículos utilizando o YOLO através do ByteTrack, onde podemos ver um ID sendo associado para cada veículo detectado.



Fonte: Autor.

4.3 Geração de histogramas de cores sob as detecções

Com base na detecção de veículos utilizando o YOLO, esta seção aborda a geração dos histogramas de cores sobre as *bounding boxes* obtidas para ao longo do projeto realizarmos o processo de comparação e rastreio. Este processo está sendo realizado através dos seguintes passos:

1. Para cada resultado na lista de detecções, é realizado a extração das coordenadas das *bounding boxes* (caixas delimitadoras).

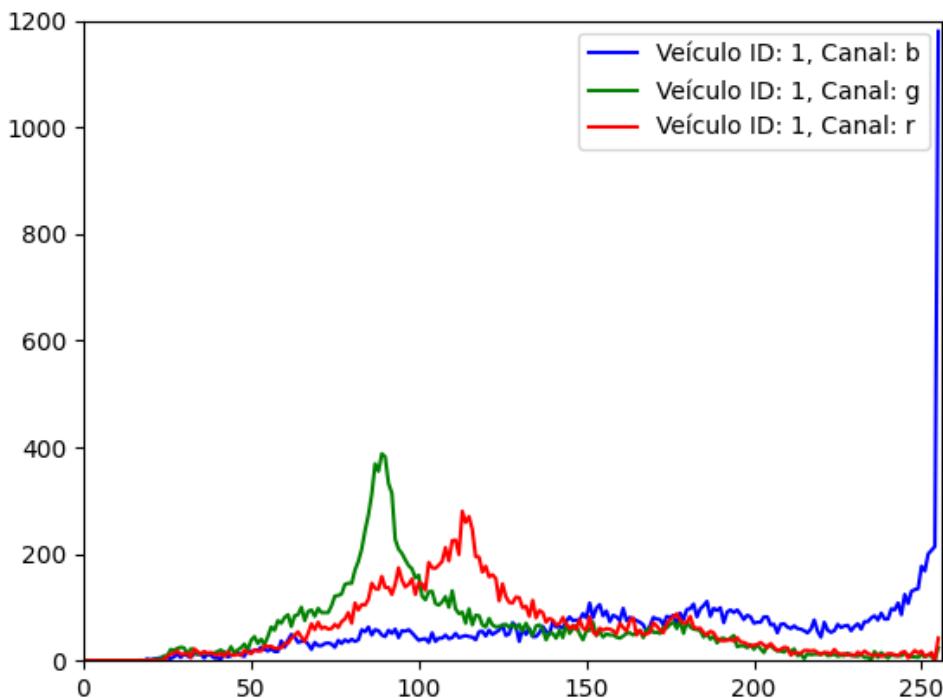
Qual a necessidade de plotar o histograma?
2. Para cada caixa delimitadora, é calculado e **plotado** o histograma das intensidades de cores para cada canal RGB na região de interesse (*ROI - Region of Interest*) correspondente.

Foi feito o redimensionamento citado na revisão (p.23) ?

3. Os gráficos resultantes são salvos individualmente com base no índice da detecção e exibidos. Por qual motivo os gráficos são salvos?

Com base na Figura 15 resultante da detecção dos veículos, as Figuras 17, 18 e 19 apresentam os histogramas gerados das *bounding boxes* dos veículos com seus respectivos ID's.

Figura 17 – Histograma gerado do veículo de ID igual a 1.



Fonte: Autor.

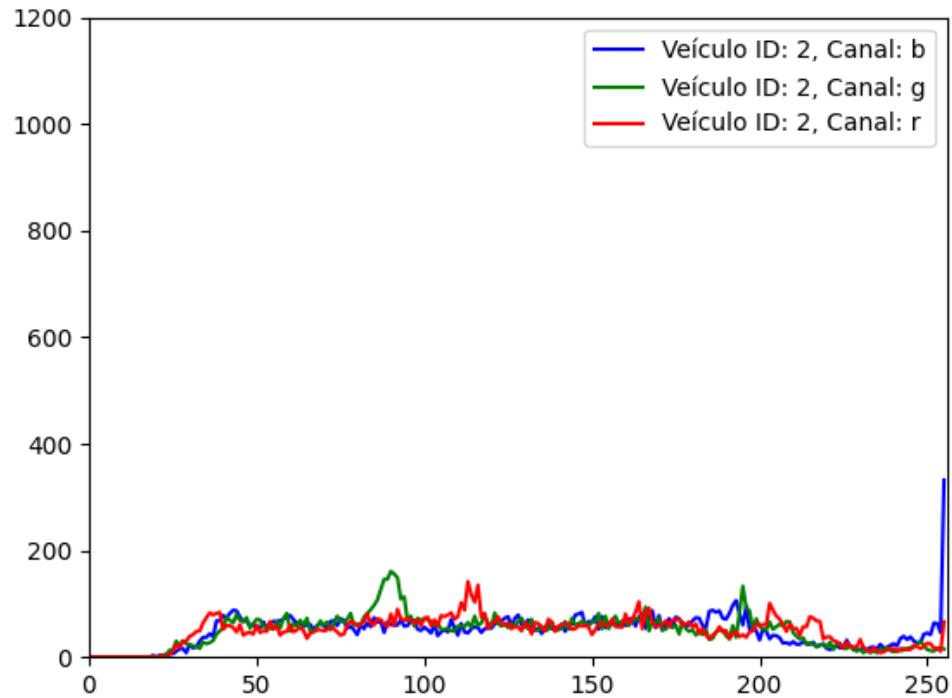
4.4 Comparação dos Histogramas através da Distância de Hellinger utilizando o Coeficiente de Bhattacharyya

Com base na geração de histogramas das detecções de veículos, será realizado ao longo deste trabalho a comparação dos histogramas equalizados através do método da Distância de Hellinger utilizando o Coeficiente de Bhattacharyya. Por meio das comparações realizadas, será possível identificar se o veículo detectado em um frame é o mesmo nos frames sucessivos, realizando-se assim o rastreio do mesmo ao longo da sua trajetória.

4.5 Comparação da taxa de acerto entre os métodos apresentados

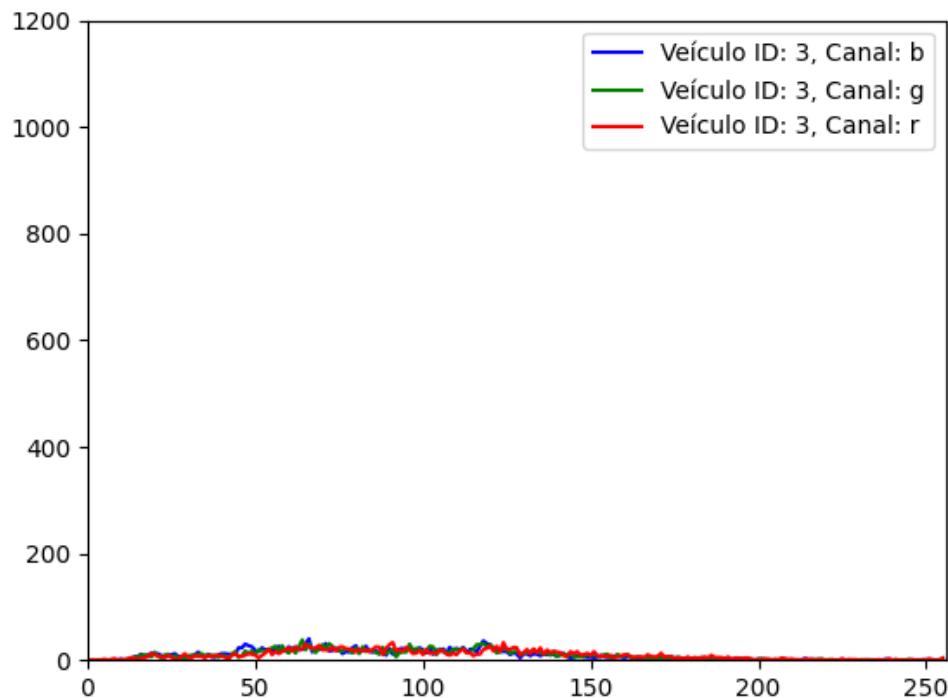
Com base nos resultados a serem obtidos, será realizada ao longo do trabalho uma comparação em relação a taxa de acerto entre o método apresentado através da

Figura 18 – Histograma gerado do veículo de ID igual a 2.



Fonte: Autor.

Figura 19 – Histograma gerado do veículo de ID igual a 3.



Fonte: Autor.

geração de histogramas para o rastreio de veículos, com o algoritmo de rastreio ByteTrack incorporado pelo YOLO. Os principais parâmetros a serem levados em conta no processo de comparação estão relacionados à precisão (proporção dos rastreios corretos feitos pelo método apresentado em relação ao total de rastreios realizados), tempo de processamento (tempo necessário para rastrear os veículos em uma ou mais imagens) e consumo de memória do método a ser apresentado.

4.6 Ambiente de desenvolvimento para testes

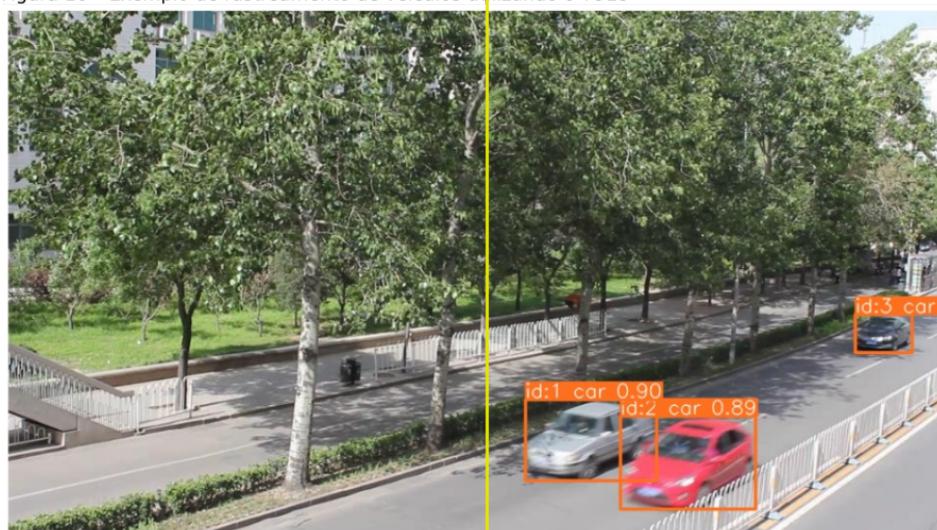
O ambiente de desenvolvimento para a execução dos testes está sendo baseado nas plataformas Visual Studio Code (MICROSOFT, 2023), fazendo o uso da linguagem de programação Python versão 3.10.11 (FOUNDATION, 2023). Das bibliotecas utilizadas ao longo do trabalho se destacam a Ultralytics (ULTRALYTICS, 2023), para a importação e testes com o YOLO; Matplotlib (TEAM, 2023b) para a plotagem e criação dos gráficos dos histogramas e OpenCV (TEAM, 2023a) para a manipulação das imagens.

Figura 15 – Exemplo de detecção de veículos utilizando o YOLOv8.



verificar a ordem de detecção e o rastreamento

Figura 16 – Exemplo de rastreamento de veículos utilizando o YOLO



5 CRONOGRAMA

Tabela 1 – Cronograma

Atividade	Março	Abril	Maio	Junho	Julho
Implementação do Método	x		x		
Execução dos Testes		x	x		
Teste e Validação			x	x	
Escrita do Trabalho	x	x	x	x	x
Apresentação do Trabalho					x

Fonte: Autor

REFERÊNCIAS

- ASHA, C.; NARASIMHADHAN, A. Vehicle counting for traffic management system using yolo and correlation filter. In: IEEE. **2018 IEEE International Conference on Electronics, Computing and Communication Technologies (CONECCT)**. [S.l.], 2018. p. 1–6. Citado na página 28.
- COIFMAN, B. et al. A real-time computer vision system for vehicle tracking and traffic surveillance. **Transportation Research Part C: Emerging Technologies**, Elsevier, v. 6, n. 4, p. 271–288, 1998. Citado na página 27.
- DIWAN, T.; ANIRUDH, G.; TEMBHURNE, J. V. Object detection using yolo: Challenges, architectural successors, datasets and applications. **multimedia Tools and Applications**, Springer, v. 82, n. 6, p. 9243–9275, 2023. Citado 2 vezes nas páginas 13 e 14.
- ERAZO, J. J. M. et al. Desenvolvimento de um sistema de contagem e classificação de veículos utilizando redes neurais convolucionais. 2021. Citado na página 14.
- FILHO, O. M.; NETO, H. V. **Processamento digital de imagens**. [S.l.]: Brasport, 1999. Citado na página 18.
- FOUNDATION, P. S. **Welcome to Python.org — python.org**. 2023. <<https://www.python.org/>>. [Accessed 25-11-2023]. Citado na página 36.
- GIRSHICK, R. et al. Region-based convolutional networks for accurate object detection and segmentation. **IEEE transactions on pattern analysis and machine intelligence**, IEEE, v. 38, n. 1, p. 142–158, 2015. Citado na página 19.
- HELLINGER, E. Neue begründung der theorie quadratischer formen von unendlichvielen veränderlichen. **Journal für die reine und angewandte Mathematik**, De Gruyter Berlin, New York, v. 1909, n. 136, p. 210–271, 1909. Citado na página 24.
- LIBERMAN, F. Classificação de imagens digitais por textura usando redes neurais. 1997. Citado 3 vezes nas páginas 15, 16 e 17.
- LYU, S. **The UA-DETRAC Benchmark Suite — detrac-db.rit.albany.edu**. 2017. <<https://detrac-db.rit.albany.edu/download>>. [Accessed 13-11-2023]. Citado 2 vezes nas páginas 31 e 32.
- MARTINS, S. Introdução ao processamento digital de imagens. **Universidade Estadual de Campinas(UNICAMP)**, 2016. Citado 2 vezes nas páginas 22 e 23.
- MASON, M.; DURIC, Z. Using histograms to detect and track objects in color video. In: IEEE. **Proceedings 30th Applied Imagery Pattern Recognition Workshop (AIPR 2001). Analysis and Understanding of Time Varying Imagery**. [S.l.], 2001. p. 154–159. Citado 3 vezes nas páginas 23, 24 e 28.
- MICROSOFT. **Visual Studio Code - Code Editing. Redefined — code.visualstudio.com**. 2023. <<https://code.visualstudio.com/>>. [Accessed 25-11-2023]. Citado na página 36.
- MONTANARI, R. **Detecção e classificação de objetos em imagens para rastreamento de veículos**. Tese (Doutorado) — Universidade de São Paulo, 2016. Citado na página 27.

OSÓRIO, F. S.; BITTENCOURT, J. R. Sistemas inteligentes baseados em redes neurais artificiais aplicados ao processamento de imagens. In: SN. **I Workshop de inteligência artificial.** [S.l.], 2000. Citado 5 vezes nas páginas 15, 16, 17, 18 e 19.

OTHMANI, M. A vehicle detection and tracking method for traffic video based on faster r-cnn. **Multimedia Tools and Applications**, Springer, v. 81, n. 20, p. 28347–28365, 2022. Citado na página 13.

PASS, G.; ZABIH, R. Comparing images using joint histograms. **Multimedia systems**, Springer, v. 7, p. 234–240, 1999. Citado na página 23.

REDMON, J. et al. You only look once: Unified, real-time object detection. In: **Proceedings of the IEEE conference on computer vision and pattern recognition.** [S.l.: s.n.], 2016. p. 779–788. Citado 3 vezes nas páginas 11, 14 e 20.

SOUSA, L. N. d. Rastreamento de veículo por gps. 2013. Citado na página 27.

TEAM, O. **Home — opencv.org.** 2023. <<https://opencv.org/>>. [Accessed 25-11-2023]. Citado na página 36.

TEAM, T. M. development. **Matplotlib &x2014; Visualization with Python — matplotlib.org.** 2023. <<https://matplotlib.org/>>. [Accessed 25-11-2023]. Citado na página 36.

ULTRALYTICS. **Home — docs.ultralytics.com.** 2023. <<https://docs.ultralytics.com/>>. [Accessed 20-11-2023]. Citado 2 vezes nas páginas 31 e 36.

VASU, L. **An effective step to real-time implementation of accident detection system using image processing.** [S.l.]: Oklahoma State University, 2010. Citado na página 18.

VELASCO, C. et al. **Monitor da Violência: Estado de SP tem 15 veículos roubados ou furtados por hora em 2023.** 2023. Disponível em: <<https://g1.globo.com/monitor-da-violencia/noticia/2023/08/13/monitor-da-violencia-estado-de-sp-tem-15-veiculos-roubados-ou-furtados-por-hora-em-2023.htm>>. Citado na página 11.

WIKIPEDIA. **Bhattacharyya distance — Wikipedia, The Free Encyclopedia.** 2023. <<http://en.wikipedia.org/w/index.php?title=Bhattacharyya%20distance&oldid=1184172710>>. [Online; accessed 10-November-2023]. Citado na página 25.

WIKIPEDIA. **Hellinger distance — Wikipedia, The Free Encyclopedia.** 2023. <<http://en.wikipedia.org/w/index.php?title=Hellinger%20distance&oldid=1150782308>>. [Online; accessed 10-November-2023]. Citado na página 25.

WIKIPEDIA. **Hellinger integral — Wikipedia, The Free Encyclopedia.** 2023. <<http://en.wikipedia.org/w/index.php?title=Hellinger%20integral&oldid=690695962>>. [Online; accessed 10-November-2023]. Citado na página 24.

ZHANG, Y. et al. Bytetrack: Multi-object tracking by associating every detection box. arxiv 2021. **arXiv preprint arXiv:2110.06864.** Citado 2 vezes nas páginas 20 e 21.

ZHANG, Y. et al. Bytetrack: Multi-object tracking by associating every detection box. In: SPRINGER. **European Conference on Computer Vision**. [S.l.], 2022. p. 1–21. Citado na página 11.

ZHAO, Z.-Q. et al. Object detection with deep learning: A review. **IEEE transactions on neural networks and learning systems**, IEEE, v. 30, n. 11, p. 3212–3232, 2019. Citado na página 13.